



Técnicas de Redes Neurais para Análise e Previsão do Mercado de Ações

G. G. Rondel

R. D. Hilkner

Relatório Técnico - IC-PFG-19-41

Projeto Final de Graduação

2019 - Dezembro

UNIVERSIDADE ESTADUAL DE CAMPINAS
INSTITUTO DE COMPUTAÇÃO

The contents of this report are the sole responsibility of the authors.
O conteúdo deste relatório é de única responsabilidade dos autores.

Técnicas de Redes Neurais para Análise e Previsão do Mercado de Ações

Giovani Garuffi Rondel*

Rodrigo Dahlstrom Hilkner*

Resumo

Esse projeto tem como intuito a análise e estudo dos desafios de previsão para o mercado financeiro. Para isso, foi pensada uma abordagem computacional que pudesse modelar e aproximar uma solução para este problema. Foi proposta uma série de diferentes configurações, técnicas e métricas para tal análise, sendo que a abordagem escolhida foi a modelagem do sistema como um problema de classificação sobre o aumento ou diminuição diário do valor da ação. Foram estudadas então duas propostas de solução baseadas em redes neurais: uma abordagem utilizando-se de uma rede tradicional multicamadas (MLP) e outra utilizando-se da rede recorrente de tipo LSTM. A partir dos resultados obtidos, foi possível concluir que a complexidade da modelagem do problema impacta diretamente em como cada algoritmo é capaz de se adequar e apresentar uma boa acurácia na predição. Por fim, nossos resultados nos levam a crer que, por mais caótico que o mercado financeiro possa parecer, ele ainda apresenta certa previsibilidade matemática e técnicas computacionais preditivas se demonstram dessa forma relevantes nesse cenário.

1 Introdução

A previsão de cotações e índices da bolsa de valores é um grande desafio, mesmo para grandes estudiosos do mercado financeiro. Prever o futuro é algo muito complexo, mas com algumas ferramentas estatísticas podemos analisar o passado em busca de algumas dicas sobre o futuro.

Nas teorias do mercado de capitais podemos encontrar desde estudos que dizem que é impossível modelar a tendência do preço de uma ação, como as teorias do Mercado Eficiente e de Random Walk, até conceitos que dizem que as mudanças no valor das ações, por mais que caóticas, não são completamente aleatórias e seguem uma tendência por algum tempo e, portanto, são previsíveis.

Neste projeto decidimos trazer uma abordagem computacional a esse problema e verificar se algoritmos baseados em aprendizado de máquina em conjunto com teorias estatísticas de **análise técnica** poderia trazer um modelo satisfatório para previsão do mercado de ações. Procuramos também entender a possível aplicabilidade real dessas técnicas como uma forma de análise automática para o comportamento de um sistema cuja previsão probabilística aparenta grande complexidade.

*Instituto de Computação, Universidade Estadual de Campinas, 13081-970 Campinas, SP.

Para isso, desenvolvemos um sistema que busca dados históricos de abertura e fechamento da bolsa de valores de uma determinada ação e, a partir dessa série temporal obtida, treina uma rede neural capaz de fazer uma previsão do comportamento que essa ação toma em uma janela de tempo diária. Para isso, utilizamos a linguagem de programação *Python* e a biblioteca *Keras*, que tem como foco o desenvolvimento de algoritmos de *Deep Learning*.

Dividimos nossos experimentos em diversas configurações, que serão detalhadas mais adiante, sendo que os modelos utilizados de redes neurais foram do tipo *Multilayer Perceptron* (MLP ou Perceptron multicamadas) e *Long Short-Term Memory* (LSTM ou Memória de longo e curto prazo).

A estrutura do documento a seguir se divide da seguinte forma: A seção 2 é dedicada à descrição completa da metodologia utilizada, desde a aquisição dos dados, tratamento desses, o algoritmo desenvolvido e como se deram os experimentos realizados. A seção 3 apresenta os resultados obtidos para todas as configurações e discute as diversas métricas e comparações obtidas para cada experimento. A próxima seção é dedicada para uma análise mais minuciosa de como cada experimento revela um aspecto diferente do problema proposto e como cada parâmetro influencia no resultado final. Por fim, apresentamos as conclusões obtidas em todo o projeto e uma janela para possíveis próximos passos a partir dos resultados alcançados. Apresentamos ainda um apêndice com todas as métricas utilizadas e resultados obtidos lado a lado para efeito de comparação.

2 Metodologia

2.1 Fundamentos da modelagem do problema

2.1.1 Sobre o mercado de ações

Há muitas teorias financeiras que tentam explicar a formação de preços de ativos no mercado de capitais. Dentre elas, uma muito debatida é a **Hipótese do Mercado Eficiente** [1]. Essa teoria segue a hipótese de que o mercado é completamente eficiente e, portanto, seus preços sempre refletem todas as informações do mercado de maneira basicamente imediata. Dessa forma, não há ação barata ou cara e, no longo prazo, não há maneira de conseguir retornos acima da média. Entretanto, há discordância sobre tal hipótese já que ela supõe que não há hiato entre um fato do mercado e o conhecimento dos investidores para considerarem o novo preço de um ativo.

Supondo que não sejam instantaneamente eficientes e que também não se comportam de maneira completamente aleatória (Teoria de Passeio Aleatório [2]) é válido o estudo e análise de modelos que tentem interpretar o mercado de ações. Para isso, algumas abordagens são mais comuns sobre a bolsa de valores, que no geral se combinam na formulação de uma estratégia bem estruturada para a previsão de preços: a interpretação de notícias, a análise técnica e a análise fundamentalista.

A **interpretação de notícias** é imprescindível para qualquer investidor. Isso poderia se encaixar em um modelo de Aprendizado de Máquina no que diz respeito a análise de sentimento a partir da mineração de dados em portais de notícias relacionadas ao mercado financeiro. A **análise fundamentalista** se baseia em analisar a saúde econômica de uma

entidade financeira, como sua receita, lucro, dívidas, gestores, entre outros. Essa é uma análise mais típica para projeções de longo prazo (meses, anos), então o projeto não trabalhou com esta análise. A **análise técnica**, por sua vez, foca mais em investimentos no curto prazo (dias) e foi o foco do projeto, como será melhor descrita a seguir.

2.1.2 Análise técnica

A **análise técnica** tenta interpretar a movimentação de preços de uma ação através da análise do comportamento de gráficos de velas. Um exemplo de gráfico de vela pode ser visto na Figura 1. É uma das ferramentas mais utilizadas pelos investidores de curto prazo, como day-traders, e tem como premissa que os preços de ações seguem tendências e que os movimentos do mercado tendem a se repetir com o tempo. Essa análise leva em conta o preço das ações e o volume de transações realizadas e tem como base a relação entre oferta e demanda, ou seja, a interpretação de se o mercado está fazendo mais pressão para que o preço de uma ação aumente ou diminua.




Figura 1: Exemplo de gráfico de velas. Neste gráfico vemos também um famoso indicador técnico, chamado Bandas de Bollinger. A principal ideia por trás do indicador é ressaltar como os preços estão dispersos em torno de um valor médio.

Os **indicadores técnicos** são instrumentos de extrema importância para a análise técnica. Existe uma variedade de indicadores técnicos e osciladores. Indicadores de tendência são os mais famosos, como médias móveis e bandas de bolinger, e tentam mostrar em qual direção o mercado está indo. Apesar de muito poderosos, em momentos em que o mercado tem baixo volume de transações eles passam a ter baixa qualidade. Os indicadores de força tem como objetivo mostrar qual a probabilidade de uma tendência a ser seguida. Já os indicadores de momento tem objetivo de mostrar a velocidade com que os preços estão mudando.

2.1.3 Redes Neurais

Redes Neurais Artificiais representam modelos computacionais cujo foco é, a partir de uma quantidade de dados, obter uma função ou um conjunto de funções que combinadas

aproximem o conjunto de dados utilizado. Tais funções são calculadas por componentes da rede denominados neurônios, e a arquitetura da rede é basicamente associada a quais tipos de neurônios são utilizados e qual a organização desses. Uma típica rede MLP é composta por um conjunto (camada) de neurônios de entrada que recebem os dados originais, uma (ou mais) camadas intermediárias (denominadas "escondidas") e uma camada final de saída que representa o valor final da predição da rede. A Figura 2 representa uma arquitetura simples de MLP.




Figura 2: Representação esquemática de um MLP de arquitetura simples contendo três neurônios de entrada, duas camadas escondidas e um neurônio de saída. Em nosso projeto, os valores desses parâmetros se acomodaram à quantidade de indicadores e dias analisados em cada passo, assim como ao número de classes previstas ao final.

Para que o aprendizado seja possível, inicialmente cada neurônio da rede é inicializado com pesos aleatórios no cálculo de suas funções. Um passo é dado na direção de entrada para a saída (*feedforward*) em que a partir dos dados de entrada é calculado o resultado de cada neurônio até a camada de saída. A partir disso, toma-se o erro entre a previsão da rede e o dado real e esse valor é então propagado de volta para a arquitetura, ao passo que os pesos de todos os neurônios são atualizadas para se adequarem melhor ao dado utilizado, por meio das técnicas *backpropagation*[7] e *gradient descent* (gradiente descendente)[8].

Para o problema proposto, temos que o conjunto de dados utilizado trata-se de uma **série temporal**, ou seja, um conjunto de observações feitas sequencialmente ao longo do tempo. Dessa forma, a informação temporal e sequencial é extremamente importante para um possível aprendizado de maior assertividade. Dado isso, nossa segunda abordagem teve como intuito explorar exatamente essa diferença entre arquiteturas, portanto nos utilizamos da arquitetura de redes neurais recorrente do tipo LSTM (*Long Short-Term Memory*).

Redes neurais recorrentes apresentam como diferencial o fato de que a cada passo no sentido direto da rede, além de ser calculada uma previsão final que terá seu erro minimizado, há também a propagação de informação entre passos, de tal maneira que a cada iteração unem-se informações do dado presente e de dados anteriores e passa a ser possível para a rede compreender relações temporais entre os diferentes dados de entrada. Os passos de propagação no sentido direto e o *backpropagation* se mantêm para esse tipo de rede. A Figura 3 representa uma arquitetura genérica de RNN e esquematiza essa propagação de informação entre passos.

A arquitetura tradicional de redes recorrentes apresenta uma série de limitações em




Figura 3: Representação esquemática de uma rede neural recorrente. A primeira imagem representa a rede simplificada, ao passo que a segunda representa seu comportamento sequencial.

seu treinamento, como o problema de *vanishing gradient*[10], que se dá pelo fato da rede receber como sinal complementar somente o resultado mais recente, de tal maneira que essa informação não se propaga por muito tempo e relações temporais mais distantes acabam por serem perdidas e não aprendidas pela rede. Dessa forma, a arquitetura LSTM[11] foi desenvolvida como uma forma de reduzir tais impactos e manter o aprendizado de relações temporais a longa distância preservados.

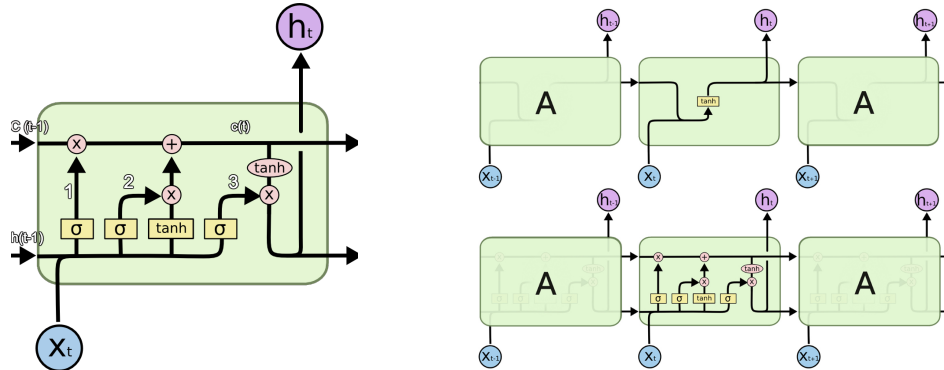


Figura 4: Representação esquemática de uma rede do tipo LSTM. À esquerda encontra-se a representação da célula LSTM, sendo representados os portões de esquecimento (1), entrada (2), saída (3). A segunda imagem representa a arquitetura completa da rede com diversas unidades LSTM alinhadas em cada camada.

A base do funcionamento da rede LSTM está em sua célula, que pode ser entendida como uma sequência de operações realizadas ao longo dos dados de entrada por suas subestruturas conhecidas como "portões" ou *gates*. São essas portões o portão de entrada (*input gate*), a de saída (*output gate*) e de esquecimento (*forget gate*). A figura 4 apresenta o funcionamento geral de uma célula LSTM e da rede como um todo. Seu funcionamento pode ser resumido de maneira que o portão de entrada contabiliza quanto um novo dado de entrada flui para a célula, o portão de esquecimento controla o quanto que um mesmo dado permanece em cada célula ao longo do tempo e o portão de saída controla o quanto o valor da célula é utilizado para computar o valor final da ativação da célula. Os pesos atribuídos a cada *gate* são parâmetros que controlam o funcionamento destes e devem ser otimizados durante o

processo de treinamento da rede.

2.2 Conjunto de dados

2.2.1 Série temporal de preços e indicadores

Inicialmente obtivemos uma série temporal diária das seguintes ações da NASDAQ: Coca-Cola Company (KO), IBM, Oracle Corporation (ORCL), NASDAQ-100 - índice das 100 maiores companhias da NASDAQ (NDX). A figura 5 representa a série temporal obtida para a empresa Coca-Cola. Foram coletados dados diários desde 1999 até 2019, sendo um total de mais de 5000 pontos para cada ação. Os treinos para cada ação foram feitos separadamente. Para cada dia coletamos o equivalente a um ponto em um gráfico de velas: o preço de abertura, fechamento, máximo, mínimo e o volume de transações realizadas naquele dia. Esses dados foram coletados através da API *Alpha Vantage* [3].




Figura 5: Na primeira imagem, valores de fechamento diário da Coca-Cola Company (NASDAQ: KO) entre dezembro de 1999 e dezembro de 2019. Na segunda, variação diária do valor da ação no mesmo período

A partir dos dados de preço e volume da ação podemos obter os indicadores técnicos desta ação com ajuda da biblioteca para Python *TA-Lib* [4]. No nosso modelo, utilizamos os seguintes indicadores [5]:

- **Média móvel simples (SMA):** Média do preço (de fechamento) da ação dos últimos N dias. No nosso modelo $N = 10$.
- **Média móvel exponencial (EMA):** é uma média móvel que dá um peso maior para os preços mais recentes. Também utilizamos $N = 10$.
- **Convergência e Divergência de Médias Móveis (MACD):** Mostra a diferença entre duas médias móveis exponenciais, uma de longo prazo (26 dias) e outra de curto prazo (12 dias).
- **Indicador de movimento direcional (ADX):** Indicador de força com o objetivo de medir quão intensa é a tendência atual, de 0 a 100. Ele também carrega 2 linhas de tendência DI^- e DI^+ , que medem as forças dos movimentos de baixa e alta, respectivamente. Quanto mais distantes estão essas curvas maior o valor do indicador.

- **Indicador de Canal de Commodities (CCI):** Faz a análise da diferença entre o preço atual e sua média móvel (de 10 dias). Geralmente vai de -100 a 100, onde um valor positivo indica que o valor atual está maior que a média móvel e um valor negativo indica o oposto.
- **Indicador de força relativa (RSI):** Consiste na divisão do ganho médio que o preço teve durante esse tempo pela perda média que sofreu e, em seguida, organiza o cálculo em uma escala de 0 a 100. Qualquer ponto acima de 70 é considerado sobrecompra e qualquer ponto abaixo de 30 é considerado sobrevenda.
- **Momentum (MOM):** É a diferença entre o preço de fechamento de uma ação hoje e N períodos atrás. Indica velocidade na valorização ou desvalorização do ativo.
- **Williams %R (WILLR):** Mais um indicador de momento que compara o preço de fechamento de um ativo, com relação ao valor mais alto e mais baixo dos últimos N dias. Para nós $N = 10$.
- **Indicador Saldo de Volume (OBV):** Calcula o saldo de volume transacionado de uma ação entre dias. Ele se baseia no conceito básico de que o volume precede o preço da ação.
- **Indicador Acumulação/Distribuição (AD):** Usa volume e preço para indicar se a ação está sendo acumulada ou distribuída, o que pode ajudar a analisar falsas tendências.
- **Índice de movimento direcional (ADOSC):** Aplica MACD sobre AD, ou seja ele calcula a diferença da média exponencial entre dois períodos do Indicador Acumulação/Distribuição.

2.2.2 Anotação

A anotação dos dados se deu a partir da variação (derivada) calculada para o valor diário da ação. A segunda figura em 5 representa essas variações para as ações da empresa Coca-Cola. A partir desse valor, foi possível então analisar o balanceamento de dias com variação positiva (aumento no valor da ação) e negativa (diminuição). Além dessa anotação binária, foi possível também subdividir o problema calculando não apenas se a ação iria aumentar ou diminuir de valor, mas também o quanto ela mudaria de valor. A anotação não-binária se deu em 8 classes, 4 sobre o aumento do valor da ação (B1, B2, B3, B4) e 4 para a redução de seu valor (S1, S2, S3, S4), que representavam respectivamente o aumento ou diminuição de: (1) até 0,5% do valor da ação; (2) até 1%; (3) até 2%; e (4) mais que 2%. As duas abordagens utilizadas, binária e não-binária, foram escolhidas de maneira que manteve-se um bom balanceamento entre as classes.

2.2.3 Normalização

Empresas comumente podem inserir e retirar papeis (ações) da bolsa, como, por exemplo, quando a empresa julga que o preço de sua ação está muito alta e decide realizar um

desdobramento de 100% de seus papéis, ou seja, cada 1 papel passa a virar 2 e o preço de cada papel cai pela metade. O processo oposto ao desdobramento é chamado de *agrupamento*. Por isso, é importante realizar a normalização dos preços e volume da série temporal: para toda a série anterior a um desdobramento de 1 para 2, por exemplo, o preço da ação foi dividido por 2 e o volume de transações multiplicado por 2.

Outro fenômeno recorrente é o pagamento de juros e dividendos pela empresa. A cada trimestre, semestre ou anualmente, uma empresa paga juros sobre capital próprio e/ou dividendos a seus acionistas. Quando isso ocorre, o valor da ação cai no mesmo valor que foi pago em juros e dividendos. Para normalizar esse valor temos que ajustar a série temporal na mesma proporção do que foi pago sobre preço da ação.

Após a etapa de normalização dos preços e volume da ação, podemos calcular os indicadores técnicos para a série em questão. Os indicadores de tendência e momento utilizados eram diretamente correlacionados com o preço da ação e foram normalizados dividindo-os por esse valor. Os indicadores de força utilizam como parâmetro o volume (OBV, AD, ADOSC) de ações transacionadas e foram normalizadas sendo divididas por este valor. Os indicadores MACD e RSI tinha valor de 0 a 100 e foi normalizado sendo dividido por 100.

2.2.4 Treino e teste

Para a separação do conjunto de dados como treino e teste, para a arquitetura MLP foi utilizada a função *train_test_split* da biblioteca de aprendizado de máquina em Python *sklearn*, que divide os dados aleatoriamente de acordo com a proporção desejada. A proporção utilizada para o treinamento foi de 30% dos dados para teste e 70% para os dados de treino. Como o modelo não se utiliza de dados sequenciais ou informações temporais, essa é a abordagem mais adequada para se reduzir o viés introduzido na rede.

Por outro lado, no caso da LSTM, a aplicação da mesma técnica não seria possível uma vez que remover dados aleatoriamente do conjunto de treinos afetaria a compreensão da rede sobre o intervalo utilizado, uma vez que resultaria em uma série temporal com "lacunas".

Dessa forma, a escolha de separação de dados preservou sua relação temporal, sendo os dados dos 5 anos mais recentes sendo utilizados para teste e os dados mais históricos utilizados como treino (e validação).

2.3 Experimentos realizados

2.3.1 Configurações utilizadas

Dividimos nossos experimentos em diversas categorias a serem analisadas.

- **Arquitetura:** Utilizamos os modelos de redes neurais MLP e LSTM.
- **Classes (Tipo de anotação):** Utilizamos dois tipos de classificação para o experimento: um problema de classificação binária, de compra/venda; e um problema multiclasse, que analisa a qualidade da compra e da venda.
- **Indicadores:** Utilizamos três diferentes subconjuntos incrementais de indicadores financeiros para estudarmos suas influências.

- **Intervalo de tempo:** Separamos três diferentes intervalos ou "janelas" de dias utilizados como entrada para cada modelo.




Figura 6: Representação esquemática da arquitetura da rede MLP implementada, com entrada do tamanho de 6 neurônios e camada de saída para a classificação binária e multiclasse, respectivamente

2.3.2 Definição da arquitetura e treinamento da rede neural

A partir de todas as configurações descritas, definimos a arquitetura dos diferentes modelos analisados de uma forma semelhante. A camada de entrada é representada pelo tamanho do intervalo de dias e do número de indicadores financeiros utilizados, ao passo que a camada de saída é do tamanho da quantidade de classes a serem previstas, sendo que para o caso de classificação binária apenas um neurônio é o suficiente. Para as camadas intermediárias, o modelo MLP foi definido por uma concatenação de duas camadas escondidas de tamanho três vezes o tamanho da entrada intercaladas por camadas de *dropout* para diminuir casos de *overfitting*, que seria o modelo ficar muito enviesado para os dados de treino e não ser capaz de generalização para dados nunca vistos. A Figura 6 representa o padrão de arquitetura utilizado, omitindo-se as camadas de *dropout*. Para os modelos LSTM, a camada intermediária foi composta por uma camada de número de células LSTM de tamanho três vezes a de entrada. Não foram utilizadas mais camadas intermediárias pois o número de parâmetros e complexidade da arquitetura resultaria também em *overfitting*. A Figura 7 exemplifica a arquitetura da rede, sendo que para o uso da LSTM como uma rede de classificação é necessário aplicar uma função *softmax* no valor de saída da representação da rede, que codifica os resultados em probabilidades de predição para cada classe. Para o treinamento, todas as redes foram treinadas utilizando-se o otimizador Adam[13].

3 Resultados e análise

As tabelas completas de comparação de todas as configurações se encontram no anexo A. De acordo com as configurações utilizadas, podemos subdividir a análise pelas discrepâncias observadas em cada categoria separadamente.

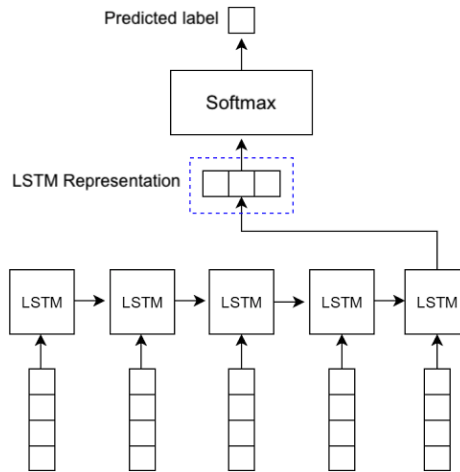


Figura 7: Representação da arquitetura da rede LSTM implementada, com a célula de saída representando a saída multiclasse e classificação binária.

- **Arquitetura:** Fica claro que para todas as situações e experimentos, a arquitetura LSTM obteve valores superiores de classificação, o que demonstra que é uma arquitetura mais especializada para aprender valores sequenciais como era o esperado. Isso fica claro pelos resultados melhores tanto nas métricas padrões de classificação como no valor calculado de lucro relativo no período.
- **Classes:** É visível que a diferença entre cada configuração altera completamente a performance. O problema de classificação binária acaba sendo um problema mais simples de tal maneira que mesmo algumas configurações mais simples da rede MLP conseguiram valores interessantes de F1-Score. Por outro lado, o problema de classificação com múltiplas classes provou-se um problema extremamente mais complexo, reduzindo todas as métricas obtidas e dificultando a obtenção de um modelo que gerasse lucro.
- **Indicadores:** Foi possível perceber que para todas as ações estudadas, as configurações de seis e oito indicadores obtiveram resultados semelhantes e em vezes melhores que a configuração com o maior número de indicadores. Fizemos uma análise de ranqueamento dos indicadores por meio da função *SelectKBest* da biblioteca *sklearn* e percebemos que os três indicadores adicionais na configuração mais complexa representavam as features com menor relevância para o conjunto de dados de todas as ações, portanto esse resultado está de acordo com nossas análises. O rank dos indicadores pode ser visto na Figura 8.
- **Intervalo de tempo:** Quanto ao tamanho dos *timesteps*, percebemos que em alguns experimentos o aumento do tamanho da janela de utilização gerou resultados satisfatórios, porém uma janela de dois dias foi uma forma suficiente (e em diversos casos, a mais eficiente) de se aprender as relações entre os comportamentos das ações. Isso nos leva a crer que matematicamente a relação entre o comportamento da ação se dá

Indicador	Score
CCI	1.434117
SMA	1.378393
EMA	1.352344
RSI	1.166768
WILLR	1.090984
MOM	1.042622
ADX	1.037812
MACD	0.955661
ADOSC	0.838434
OBV	0.721207
AD	0.60398

Figura 8: Ranking de indicadores para as ações da Coca-Cola Company (NASDAQ: KO). No topo vemos os clássicos índices relacionados a médias móveis (CCI, SMA e EMA) e com as piores colocações temos os indicadores de volume (ADOSC, OBV e AD).

de uma forma majoritariamente próxima, e efeitos que ocorrem em janelas maiores de dias, como por exemplo de uma semana de distância, acabam por não influenciar no valor de forma tão direta.

Para cada modelo foi calculado o lucro teórico a partir de um algoritmo que, de acordo com as previsões do modelo, tomava a decisão de comprar ações, vender ações ou não realizar nenhuma transação. Para os modelos de 2 classes (classificação binária), a classificação simplesmente analisava se o modelo previa compra ou venda em determinado momento e executava essa ação. Para os modelos de 8 classes (não binário que analisa a qualidade da compra e venda), a ação era comprada para qualquer das classificações B1, B2, B3, B4 (que indicavam que as ações iriam aumentar de valor no dia seguinte até 0,5%, até 1,0%, até 2,0% ou mais que 2,0%) e era vendida se as classificações S1, S2, S3, S4 (semelhante à situação de compra, mas indicando que o valor da ação iria cair). A imagem 9 representa o lucro obtido para um experimento específico.

Foi possível, a partir dos resultados obtidos para a classificação do modelo e do teste de lucro simulado, perceber que para uma situação de perda e ganho diário como a proposta, erros de predição influenciam negativamente de uma forma excessiva nos resultados finais, uma vez que um caso de classificação incorreta não só significa um menor ganho como na verdade implica em uma perda. Assim, mesmo com modelos com acurácia acima do valor de 70%, a natureza do problema se mostrou complexa o suficiente para que não houvesse lucro real obtido.

Para o caso de classificação binária, porém, por se tratar de um problema mais simples, foi possível perceber um retorno financeiro real para o estudo proposto. Nesse caso, podemos perceber também como o fato da arquitetura LSTM utilizar-se das informações sequenciais prevaleceu para a obtenção de melhores resultados. Uma outra observação obtida a partir da análise dos resultados foi a diferença entre os períodos de treino e testes utilizados.



Figura 9: Lucro obtido para o modelo de rede LSTM, com 2 classes, janela de 5 dias e 3 indicadores. Lucro total de 12,44% ao ano no período testado, sendo que as ações aumentaram 3,58% ao ano nesse período.




Figura 10: Na primeira imagem, valores de fechamento diário da empresa Microsoft (NASDAQ: MSFT). É possível perceber o aumento vertiginoso no valor da ação que ocorre no período de 5 anos mais recentes. Na segunda imagem, temos os valores para a Oracle Corporation (NYSE: ORCL), que apresenta um crescimento constante porém mais aproximadamente linear.

Na maior parte das ações analisadas, apesar de todas apresentarem aumento entre o período inicial e o final estudados, é possível perceber por meio da Figura 10 que o comportamento particularmente da ação MSFT no período a partir de 2014 se comporta de maneira praticamente exponencial, em contraste com seus valores encontrados até o momento. Essa discrepância e repentina alteração no comportamento dessa ação foi determinante no desempenho reduzido para todos os modelos quando confrontados com esse conjunto de dados.

4 Conclusão

A abordagem computacional ao clássico problema de previsão de séries temporais relacionada ao mercado financeiro se mostra interessante. Por mais que os resultados não tenham sido completamente consistentes nas diferentes ações analisadas, podemos ver que existem algumas correlações entre os modelos utilizados e resultados obtidos que devem ser

exploradas com mais atenção.

O problema de predição de valores futuros de ativos é um clássico desafio do mercado financeiro. No nosso projeto tentamos mostrar alguma conexão entre os indicadores utilizados como entrada dos modelos e o valor futuro das ações e foi possível mostrar que há relação em grande nível entre esses valores. As taxas de precisão dos modelos mostram com segurança que os indicadores técnicos podem ser utilizados para prever tendências da bolsa de valores, fato que embate diretamente com a *Teoria de Random Walk* [2] e mostra, mais uma vez, que o mercado se comporta de maneira caótica, mas de maneira nenhuma é completamente aleatório.

Fato interessante é que apesar de ser possível acusar uma refutação da *Teoria de Random Walk* não podemos dizer o mesmo sobre a *Hipótese do Mercado Eficiente* [1]. A alta acurácia do modelo afirma o primeiro, mas o baixo nível de lucro teórico entre os modelos tende a assumir que o mercado de ações tem grande eficiência e que as ações rapidamente atingem um novo patamar de estabilidade. Realizar uma análise técnica sem a interpretação de notícias e fatos externos é arriscado, já que o investidor passa a depender das informações já refletidas nos preços dos ativos ao invés de obtê-los de antemão. O entendimento dos fatos que afetam o mercado é necessário para que o investidor possa obter vantagem sobre os demais através de uma entrada anterior em um mercado que irá se aquecer.

Sabemos que por mais que a abordagem tenha tido algum nível de sucesso ainda há alguns pontos a se melhorar. A análise técnica tem muito valor, mas a hipótese explorada leva em consideração somente os valores diretos da ação, de tal maneira que não permite muita influência de fatores externos, o que sabemos que não é verdade para o caso de valores de ações. Uma notícia, um escândalo ou acontecimentos políticos podem alterar diretamente esse mercado, de tal maneira que somente uma análise direcionada aos valores seria incapaz de captar. Dessa maneira, uma abordagem que tente captar essas influências e nuances externos que envolvem uma certa ação ou empresa seriam de grande valor para o entendimento do comportamento geral dessa. Uma análise de sentimento relacionado às tendências do mercado de ações poderia direcionar muito melhor ações que potencialmente teriam melhor retorno. Além disso, levamos em conta a hipótese de que um número maior de pontos para treinamento e teste poderia reverter em um resultado substancialmente melhor, mas infelizmente não é tão fácil encontrar portais gratuitos com tais dados.

Por fim, os valores de acurácia alcançados nos experimentos e as compreensões obtidas a partir do estudo do funcionamento do mercado e dos valores de ações demonstram que o desenvolvimento de soluções computacionais para auxiliar em tomadas de decisões para esse tipo de problema uma área extremamente promissora.

Referências

- [1] Malkiel, B. G., and Fama, E. F. (1970), *Efficient Capital Markets; a review of theory and empirical work*, Journal of Finance.
- [2] Malkiel, B. G. (1973), A Random Walk Down Wall Street

- [3] *Alpha Vantage, Realtime and historical stock data*, available at: <https://www.alphavantage.co/> (accessed 1 November 2019).
- [4] *TA-Lib, Technical Analysis Library - Python wrapper*, available at: <https://mrjbq7.github.io/ta-lib/> (accessed 1 December 2019).
- [5] *List of Technical Indicators — Trading Technologies*, available at: <https://www.tradingtechnologies.com/xtrader-help/x-study/technical-indicator-definitions/list-of-technical-indicators/> (accessed 1 November 2019).
- [6] Dorffner, G., *Neural networks for time series processing*, Neural Network World, 1996.
- [7] LeCun, Yann, et al. *A theoretical framework for back-propagation*. Proceedings of the 1988 connectionist models summer school. Vol. 1. CMU, Pittsburgh, Pa: Morgan Kaufmann, 1988.
- [8] A. Cauchy. Méthode générale pour la résolution des systèmes d'équations simultanées. C. R. Acad. Sci. Paris, 536–538, 1847.
- [9] Sherstinsky, Alex. *Fundamentals of recurrent neural network (RNN) and long short-term memory (LSTM) network*. arXiv preprint arXiv:1808.03314 (2018).
- [10] Pascanu, Razvan, Tomas Mikolov, and Yoshua Bengio. *On the difficulty of training recurrent neural networks*. International conference on machine learning. 2013.
- [11] Hochreiter, Sepp, and Jürgen Schmidhuber. *Long short-term memory*. Neural computation 9.8 (1997): 1735-1780.
- [12] Olah, C. (2015), *Understanding LSTM Networks*, available at: <http://colah.github.io/posts/2015-08-Understanding-LSTMs/> (accessed 1 November 2019).
- [13] Kingma, Diederik P., and Jimmy Ba. *Adam: A method for stochastic optimization*. arXiv preprint arXiv:1412.6980 (2014).

A Resultados completos

Para todos as tabelas de resultados a seguir, segue a legenda.

- **Modelo:** Representa a configuração de modelo no qual o experimento foi executado.
 - **A:** Arquitetura de Rede Neural.
 - **C:** Número de classes para previsão.
 - **J:** Intervalo de tempo (Janela) de dias na entrada do modelo.
 - **I:** Quantidade de indicadores financeiros utilizados.
- **Resultado:** Métricas obtidas após o treinamento do modelo.

- **Lucro relativo:** Valor relativo entre o lucro obtido a partir do algoritmo descrito na seção 3 e o valor total de crescimento da ação no período analisado.
- **% Lucro/ano:** Valor em porcentagem do crescimento anual da simulação de investimento.
- **F1-Score, Precision, Recall:** Métricas de classificação.

KO								
Modelo				Resultado				
R	C	J	A	Lucro relativo	% Lucro/ano	F1-Score	Precision	Recall
MLP	2	2	3	-7.39%	1.31%	0.759000	0.759073	0.758208
MLP	2	2	6	-8.33%	0.28%	0.967000	0.967732	0.967895
MLP	2	2	8	-7.53%	1.15%	0.958000	0.959901	0.957124
MLP	2	2	11	-6.75%	2.01%	0.786000	0.797835	0.782641
MLP	2	5	3	-5.50%	3.37%	0.801000	0.801187	0.801700
MLP	2	5	6	-6.88%	1.87%	0.896000	0.916800	0.891441
MLP	2	5	8	-5.10%	3.81%	0.946000	0.945801	0.946073
MLP	2	5	11	-4.96%	3.96%	0.773000	0.772920	0.773398
MLP	2	10	3	-3.44%	5.63%	0.797798	0.797397	0.796378
MLP	2	10	6	-2.36%	6.81%	0.943944	0.943748	0.943748
MLP	2	10	8	-7.66%	1.01%	0.847848	0.848004	0.849214
MLP	2	10	11	-1.26%	8.01%	0.760761	0.765345	0.764254
LSTM	2	2	3	6.80%	16.83%	0.765000	0.762288	0.757496
LSTM	2	2	6	2.00%	11.58%	0.982000	0.981267	0.982222
LSTM	2	2	8	2.24%	11.84%	0.983000	0.983660	0.981830
LSTM	2	2	11	1.20%	10.70%	0.756000	0.768361	0.736956
LSTM	2	5	3	3.31%	13.01%	0.755000	0.759341	0.762699
LSTM	2	5	6	2.85%	12.51%	0.953000	0.951330	0.953650
LSTM	2	5	8	1.38%	10.90%	0.926000	0.923658	0.928135
LSTM	2	5	11	0.01%	9.40%	0.725000	0.720693	0.717619
LSTM	2	10	3	1.96%	11.54%	0.704705	0.699808	0.698099
LSTM	2	10	6	-2.68%	6.46%	0.913914	0.911685	0.916871
LSTM	2	10	8	0.96%	10.44%	0.874875	0.872711	0.873266
LSTM	2	10	11	1.24%	10.75%	0.927928	0.927399	0.934162
MLP	8	2	3	-1.27%	8.00%	0.013889	0.875000	0.007000
MLP	8	2	6	-1.98%	7.23%	0.647025	0.746405	0.571000
MLP	8	2	8	-4.00%	5.01%	0.621993	0.727882	0.543000
MLP	8	2	11	-8.46%	0.14%	0.033010	0.566667	0.017000
MLP	8	5	3	-7.66%	1.01%	0.031311	0.727273	0.016000
MLP	8	5	6	-4.61%	4.35%	0.658172	0.737888	0.594000
MLP	8	5	8	-2.70%	6.44%	0.513980	0.634361	0.432000
MLP	8	5	11	-1.98%	7.23%	0.041083	0.309859	0.022000
MLP	8	10	3	-7.66%	1.01%	0.051282	0.500000	0.027027
MLP	8	10	6	-5.34%	3.55%	0.619312	0.694894	0.558559
MLP	8	10	8	-6.85%	1.90%	0.431535	0.529070	0.364364
MLP	8	10	11	-6.38%	2.41%	0.057296	0.271186	0.032032
LSTM	8	2	3	-9.89%	-1.43%	0.021569	0.550000	0.011000
LSTM	8	2	6	-10.53%	-2.13%	0.736896	0.757928	0.717000
LSTM	8	2	8	-9.62%	-1.13%	0.722307	0.730809	0.714000
LSTM	8	2	11	-5.97%	2.86%	0.428946	0.450937	0.409000
LSTM	8	5	3	-14.80%	-6.80%	0.261267	0.376648	0.200000
LSTM	8	5	6	-7.80%	0.86%	0.665997	0.669021	0.663000
LSTM	8	5	8	-10.23%	-1.80%	0.589653	0.592331	0.587000
LSTM	8	5	11	-7.82%	0.84%	0.462921	0.528205	0.412000
LSTM	8	10	3	-17.27%	-9.50%	0.309204	0.319786	0.299299
LSTM	8	10	6	-6.45%	2.33%	0.688377	0.689067	0.687688
LSTM	8	10	8	-7.01%	1.72%	0.585765	0.599581	0.572573
LSTM	8	10	11	-9.07%	-0.53%	0.495029	0.518640	0.473473

Figura 11: Resultados dos experimentos para ações da Coca-Cola Company.

IBM								
Modelo				Resultado				
A	C	J	I	Lucro relativo	% Lucro/ano	F1-Score	Precision	Recall
MLP	2	2	3	2.09%	5.75%	0.763000	0.763955	0.762285
MLP	2	2	6	1.77%	5.41%	0.991000	0.990958	0.991136
MLP	2	2	8	2.84%	6.52%	0.970000	0.971154	0.970588
MLP	2	2	11	-0.47%	3.09%	0.851000	0.853933	0.851921
MLP	2	5	3	-0.84%	2.71%	0.784000	0.797704	0.781793
MLP	2	5	6	-3.79%	-0.34%	0.979000	0.979022	0.979212
MLP	2	5	8	-3.66%	-0.21%	0.950000	0.952913	0.949260
MLP	2	5	11	-7.75%	-4.45%	0.830000	0.830018	0.829812
MLP	2	10	3	-3.81%	-0.37%	0.807808	0.809609	0.810045
MLP	2	10	6	-6.52%	-3.17%	0.932933	0.943119	0.928989
MLP	2	10	8	-11.39%	-8.22%	0.916917	0.916433	0.917390
MLP	2	10	11	-8.07%	-4.78%	0.795796	0.795189	0.794900
LSTM	2	2	3	6.52%	10.33%	0.766000	0.781885	0.764052
LSTM	2	2	6	-2.48%	1.01%	0.984000	0.984034	0.983964
LSTM	2	2	8	-0.10%	3.48%	0.982000	0.982040	0.982155
LSTM	2	2	11	2.30%	5.96%	0.951000	0.951460	0.950779
LSTM	2	5	3	8.55%	12.44%	0.798000	0.801923	0.797052
LSTM	2	5	6	-0.79%	2.76%	0.968000	0.968591	0.968344
LSTM	2	5	8	-0.64%	2.92%	0.954000	0.954093	0.954180
LSTM	2	5	11	-2.09%	1.42%	0.937000	0.937504	0.937320
LSTM	2	10	3	6.14%	9.94%	0.696697	0.696644	0.696523
LSTM	2	10	6	-0.39%	3.18%	0.958959	0.961010	0.959506
LSTM	2	10	8	-0.97%	2.58%	0.937938	0.938213	0.937774
LSTM	2	10	11	-1.98%	1.53%	0.946947	0.946949	0.946920
MLP	8	2	3	-7.17%	-3.85%	0.027532	0.823529	0.014000
MLP	8	2	6	-5.13%	-1.73%	0.641764	0.827804	0.524000
MLP	8	2	8	-4.57%	-1.15%	0.665537	0.764935	0.589000
MLP	8	2	11	-6.12%	-2.76%	0.134752	0.593750	0.076000
MLP	8	5	3	-3.28%	0.18%	0.059501	0.738095	0.031000
MLP	8	5	6	-0.12%	3.46%	0.717380	0.760358	0.679000
MLP	8	5	8	-1.34%	2.19%	0.672796	0.732627	0.622000
MLP	8	5	11	-2.78%	0.70%	0.135593	0.444444	0.080000
MLP	8	10	3	0.45%	4.05%	0.095327	0.718310	0.051051
MLP	8	10	6	10.09%	14.03%	0.669913	0.729093	0.619620
MLP	8	10	8	7.11%	10.95%	0.573427	0.619767	0.533534
MLP	8	10	11	5.87%	9.66%	0.160123	0.346667	0.104104
LSTM	8	2	3	-8.91%	-5.65%	0.035054	0.666667	0.018000
LSTM	8	2	6	-4.73%	-1.32%	0.740625	0.772826	0.711000
LSTM	8	2	8	-6.42%	-3.07%	0.766174	0.780893	0.752000
LSTM	8	2	11	-2.28%	1.22%	0.536989	0.556270	0.519000
LSTM	8	5	3	-8.71%	-5.44%	0.162386	0.473430	0.098000
LSTM	8	5	6	0.88%	4.49%	0.723038	0.732308	0.714000
LSTM	8	5	8	-1.84%	1.67%	0.641566	0.644153	0.639000
LSTM	8	5	11	-2.63%	0.86%	0.468880	0.487069	0.452000
LSTM	8	10	3	-12.25%	-9.11%	0.240529	0.301205	0.200200
LSTM	8	10	6	2.38%	6.05%	0.723170	0.724623	0.721722
LSTM	8	10	8	-0.04%	3.54%	0.637240	0.646091	0.628629
LSTM	8	10	11	-4.06%	-0.62%	0.448864	0.519054	0.395395

Figura 12: Resultados dos experimentos para ações da IBM.

ORCL								
Modelo				Resultado				
A	C	J	I	Lucro relativo	% Lucro/ano	F1-Score	Precision	Recall
MLP	2	2	3	-21.87%	-12.16%	0.778000	0.778205	0.777800
MLP	2	2	6	-13.93%	-3.23%	0.980000	0.980032	0.980093
MLP	2	2	8	-9.54%	1.71%	0.959000	0.959014	0.959078
MLP	2	2	11	-14.78%	-4.18%	0.866000	0.871316	0.865285
MLP	2	5	3	-9.81%	1.40%	0.800000	0.800790	0.800645
MLP	2	5	6	-12.09%	-1.16%	0.952000	0.953987	0.951239
MLP	2	5	8	-9.71%	1.52%	0.916000	0.915915	0.915995
MLP	2	5	11	-5.83%	5.88%	0.812000	0.812004	0.811665
MLP	2	10	3	-2.99%	9.07%	0.807808	0.807588	0.807664
MLP	2	10	6	-5.96%	5.73%	0.868869	0.894193	0.864720
MLP	2	10	8	-0.41%	11.97%	0.863864	0.863917	0.864311
MLP	2	10	11	-0.58%	11.78%	0.803804	0.805849	0.802265
LSTM	2	2	3	4.31%	17.28%	0.741000	0.766281	0.724640
LSTM	2	2	6	-12.72%	-1.87%	0.975000	0.976751	0.973253
LSTM	2	2	8	-8.44%	2.94%	0.940000	0.941748	0.944954
LSTM	2	2	11	5.53%	18.65%	0.767000	0.794779	0.780069
LSTM	2	5	3	-0.10%	12.32%	0.727000	0.725112	0.722502
LSTM	2	5	6	-10.51%	0.62%	0.953000	0.954140	0.951255
LSTM	2	5	8	-9.40%	1.86%	0.886000	0.885589	0.888698
LSTM	2	5	11	-0.45%	11.93%	0.821000	0.819779	0.818903
LSTM	2	10	3	1.11%	13.68%	0.667668	0.664952	0.665071
LSTM	2	10	6	-10.95%	0.12%	0.951952	0.951283	0.951918
LSTM	2	10	8	-5.06%	6.75%	0.925926	0.924982	0.925858
LSTM	2	10	11	-5.51%	6.24%	0.850851	0.849929	0.848959
MLP	8	2	3	7.46%	20.82%	0.092628	0.844828	0.049000
MLP	8	2	6	0.50%	13.00%	0.524183	0.756604	0.401000
MLP	8	2	8	-0.16%	12.25%	0.552534	0.723301	0.447000
MLP	8	2	11	1.25%	13.84%	0.204329	0.761290	0.118000
MLP	8	5	3	-1.30%	10.97%	0.136445	0.666667	0.076000
MLP	8	5	6	-2.18%	9.98%	0.543571	0.695788	0.446000
MLP	8	5	8	-3.79%	8.17%	0.497849	0.645933	0.405000
MLP	8	5	11	-6.11%	5.57%	0.140652	0.493976	0.082000
MLP	8	10	3	-12.54%	-1.66%	0.145553	0.710526	0.081081
MLP	8	10	6	-5.95%	5.75%	0.576251	0.724242	0.478478
MLP	8	10	8	-8.22%	3.19%	0.369681	0.550495	0.278278
MLP	8	10	11	-8.63%	2.73%	0.180791	0.466667	0.112112
LSTM	8	2	3	-5.51%	6.24%	0.850851	0.849929	0.848959
LSTM	8	2	6	-12.70%	-1.85%	0.021505	0.478261	0.011000
LSTM	8	2	8	1.03%	13.59%	0.668090	0.716247	0.626000
LSTM	8	2	11	-3.34%	8.68%	0.624277	0.657807	0.594000
LSTM	8	5	3	-8.70%	2.65%	0.312437	0.315951	0.309000
LSTM	8	5	6	-16.32%	-5.92%	0.171725	0.330484	0.116000
LSTM	8	5	8	0.48%	12.97%	0.566785	0.575851	0.558000
LSTM	8	5	11	-8.58%	2.79%	0.483072	0.488253	0.478000
LSTM	8	10	3	-10.58%	0.54%	0.283688	0.287474	0.280000
LSTM	8	10	6	-3.34%	8.68%	0.248848	0.254717	0.243243
LSTM	8	10	8	-2.36%	9.78%	0.553364	0.559305	0.547548
LSTM	8	10	11	0.83%	13.37%	0.408451	0.410516	0.406406

Figura 13: Resultados dos experimentos para ações da Oracle Corporation.

MSFT								
Modelo				Resultado				
A	C	J	I	Lucro relativo	% Lucro/ano	F1-Score	Precision	Recall
MLP	2	2	3	-10.50%	17.47%	0.750000	0.753326	0.748739
MLP	2	2	6	-14.47%	12.26%	0.963000	0.964576	0.962485
MLP	2	2	8	-10.62%	17.31%	0.948000	0.948428	0.947739
MLP	2	2	11	-11.05%	16.75%	0.846000	0.846440	0.846379
MLP	2	5	3	-18.05%	7.56%	0.822000	0.822560	0.821734
MLP	2	5	6	-20.40%	4.48%	0.962000	0.961982	0.962019
MLP	2	5	8	-16.70%	9.33%	0.926000	0.929080	0.925509
MLP	2	5	11	-13.18%	13.95%	0.812000	0.816042	0.812669
MLP	2	10	3	-17.56%	8.21%	0.779780	0.784552	0.782393
MLP	2	10	6	-14.58%	12.12%	0.914915	0.923900	0.911951
MLP	2	10	8	-12.12%	15.34%	0.832833	0.834906	0.830925
MLP	2	10	11	-18.05%	7.56%	0.756757	0.760342	0.759025
LSTM	2	2	3	-11.55%	16.09%	0.745000	0.784741	0.717468
LSTM	2	2	6	-17.09%	8.82%	0.961000	0.959119	0.965302
LSTM	2	2	8	-16.57%	9.51%	0.972000	0.970795	0.972570
LSTM	2	2	11	-4.51%	25.33%	0.749000	0.745865	0.748481
LSTM	2	5	3	-12.22%	15.22%	0.710000	0.718384	0.719576
LSTM	2	5	6	-14.98%	11.59%	0.953000	0.952589	0.951888
LSTM	2	5	8	-16.42%	9.70%	0.942000	0.945681	0.937316
LSTM	2	5	11	-11.78%	15.79%	0.725000	0.741959	0.738966
LSTM	2	10	3	-3.71%	26.38%	0.702703	0.701094	0.688490
LSTM	2	10	6	-17.69%	8.03%	0.950951	0.953902	0.947067
LSTM	2	10	8	-14.00%	12.88%	0.887888	0.885439	0.889166
LSTM	2	10	11	-1.85%	28.82%	0.743744	0.746686	0.750061
MLP	8	2	3	-20.37%	4.52%	0.033399	0.944444	0.017000
MLP	8	2	6	-13.89%	13.02%	0.563507	0.793103	0.437000
MLP	8	2	8	-16.09%	10.14%	0.535512	0.720812	0.426000
MLP	8	2	11	-15.61%	10.76%	0.057143	0.600000	0.030000
MLP	8	5	3	-9.52%	18.76%	0.110092	0.666667	0.060000
MLP	8	5	6	-5.05%	24.62%	0.638030	0.746649	0.557000
MLP	8	5	8	-5.59%	23.92%	0.557415	0.658936	0.483000
MLP	8	5	11	-7.34%	21.62%	0.101695	0.471074	0.057000
MLP	8	10	3	-9.74%	18.47%	0.115279	0.670213	0.063063
MLP	8	10	6	-4.99%	24.71%	0.592239	0.733728	0.496496
MLP	8	10	8	-10.04%	18.08%	0.384713	0.528897	0.302302
MLP	8	10	11	-5.31%	24.28%	0.127178	0.489933	0.073073
LSTM	8	2	3	-14.15%	12.68%	0.028958	0.416667	0.015000
LSTM	8	2	6	-6.29%	23.00%	0.656764	0.699435	0.619000
LSTM	8	2	8	-4.84%	24.90%	0.564157	0.600451	0.532000
LSTM	8	2	11	-18.51%	6.96%	0.360000	0.369474	0.351000
LSTM	8	5	3	-6.08%	23.28%	0.191057	0.296218	0.141000
LSTM	8	5	6	-7.29%	21.68%	0.529708	0.533469	0.526000
LSTM	8	5	8	-13.05%	14.13%	0.425618	0.429298	0.422000
LSTM	8	10	3	-15.90%	10.38%	0.203476	0.207941	0.199199
LSTM	8	10	6	-1.93%	28.72%	0.493715	0.495960	0.491491
LSTM	8	10	8	-7.93%	20.84%	0.412923	0.416497	0.409409
LSTM	8	10	11	-6.41%	22.84%	0.295560	0.308950	0.283280

Figura 14: Resultados dos experimentos para ações da Microsoft.