

CURSO DE CIÊNCIA DA COMPUTAÇÃO

Tauame Aguiar Pacce

**Estratégia de Negociação baseada em Inteligência Artificial para atuação em Mercados  
de Capitais**

Santa Cruz do Sul

2017

Tauame Aguiar Pacce

**Estratégia de Negociação baseada em Inteligência Artificial para atuação em Mercados de Capitais**

Trabalho de Conclusão apresentado ao Curso de Ciência da Computação da Universidade de Santa Cruz do Sul, para obtenção do título de Bacharel em Ciência da Computação.

Orientadora: Prof<sup>a</sup>. Dr<sup>a</sup>. Rejane Frozza

Santa Cruz do Sul

2017

## RESUMO

O uso de estratégias de negociação automatizadas auxilia no aumento de lucros com riscos mais baixos. As estratégias criadas pelos investidores podem não levar em conta as emoções que surgem em decorrência de momentos de fortes altas ou baixas do mercado. Assim, o objetivo deste trabalho foi desenvolver uma estratégia de negociação baseada em *eXtended Classifier Systems* e Programação Genética aliada a indicadores técnicos do mercado de capitais. O sistema foi desenvolvido na plataforma *MetaTrader 5* e avaliado utilizando uma janela deslizante de 2 anos sobre *candles* diários do ativo PETR4 da BM&F Bovespa entre janeiro de 2014 e janeiro de 2017. Foram utilizados oito indicadores técnicos para identificar tendências e pontos de entrada e saída: *Chaikin Oscillator*, *Money Flow Index*, Tripla Média Móvel, MACD, RSI, *Parabolic SAR*, *Rate of Change* e ADX. Para avaliar o sistema desenvolvido, foram realizadas 10 simulações, utilizando um período de 3 anos com uma janela deslizante de 2 anos, e evoluindo uma base de classificadores. A estratégia desenvolvida obteve lucro médio de 55% em 3 anos, apesar do alto *drawdown* e grande número de negociações perdedoras.

Palavras chave: Mercado de capitais, *eXtended Classifier System*, Programação Genética, Estratégia de negociação automatizada.

## ABSTRACT

Usage of automated trading strategies helps increase profits with lower risks. Strategies created by investors may not consider arising emotions as a result of bullish or bearish markets. Thus, the objective of this paper is to develop a trading strategy based on eXtended Classifier Systems and Genetic Programming combined with stock market technical indicators. The system was developed on MetaTrader 5 platform and evaluated using a 2-year sliding window on PETR4 daily candles on BM&F Bovespa between January 2014 and January 2017. Eight technical indicators were used to identify trends and entry and exit points: Chaikin Oscillator, Money Flow Index, Triple Moving Average, MACD, RSI, Parabolic SAR, Rate of Change and ADX. In order to evaluate the developed system, 10 simulations were carried during a 3 years period with a 2 years sliding window and evolving a classifiers pool. The strategy developed earned an average 55% profit in 3 years, despite the high drawdown and large number of losing trades.

Key words: Stock Market, *eXtended Classifier System*, Genetic Programming, Automated trading strategy.

## LISTA DE FIGURAS

Figura 1 – <i>Candles</i> de baixa e de alta. ....	15
Figura 2 – Média móvel aplicada ao ativo Dow Industrials entre os anos 1970 e 1993. .....	16
Figura 3 – Linhas de suporte e resistência no gráfico semanal do contrato de Dólar Mini. ....	17
Figura 4 – Sinais do indicador RSI de 12 dias no gráfico diário do ativo PETR4. ....	19
Figura 5 – Sinais do indicador MACD no gráfico diário do ativo PETR4.....	20
Figura 6 – Modelo matemático do neurônio de McCulloch e Pitts. ....	22
Figura 7 – Indivíduo representando uma regra de negociação. ....	25
Figura 8 – Etapas do desenvolvimento. ....	34
Figura 9 – Arquitetura do sistema desenvolvido ....	35
Figura 10 – Exemplo de árvore de decisão do classificador. ....	38
Figura 11 – Rotina “ <i>RUN GA</i> ”. ....	39
Figura 12 – Compilação do código-fonte no <i>MetaEditor</i> . ....	44
Figura 13 – <i>Strategy Tester</i> dentro da plataforma <i>MetaTrader 5</i> . ....	45
Figura 14 – Visualização da simulação no <i>Strategy Tester</i> . ....	46
Figura 15 – Janela deslizando. ....	48
Figura 16 – Relatório da simulação gerado pelo <i>MetaTrader 5</i> . ....	49
Figura 17 – Saldo da conta durante as simulações. ....	51
Figura 18 – Saldo da conta utilizando a estratégia <i>Buy-and-Hold</i> . ....	52

## **LISTA DE TABELAS E QUADROS**

Tabela 1 – Desempenho comparado entre ELM, BP e SVR para o problema SinC.....	233
Tabela 2 – Resultados obtidos das 10 simulações.....	50
Quadro 1 – Quadro comparativo dos trabalhos relacionados – Estratégias de Negociação no Mercado de Capitais .....	30

## LISTA DE ABREVIATURAS

<b>BM&amp;F</b>	Bolsa de Mercadorias e Futuros
<b>BOVESPA</b>	Bolsa de Valores do Estado de São Paulo
<b>BP</b>	<i>Backpropagation</i>
<b>CEFLANN</b>	<i>Computational Efficient Functional Link Artificial Neural Network</i>
<b>CVM</b>	Comissão de Valores Mobiliários
<b>EA</b>	<i>Expert Advisor</i>
<b>ELM</b>	<i>Extreme Learning Machine</i>
<b>FOREX</b>	<i>Foreign Exchange</i>
<b>LCS</b>	<i>Learning Classifier System</i>
<b>MACD</b>	<i>Moving Average Convergence/Divergence</i>
<b>OPA</b>	Oferta Pública de Ações
<b>PG</b>	Programação Genética
<b>PSO</b>	<i>Particle Swarm Optimization</i>
<b>RSI</b>	<i>Relative Strength Index</i>
<b>UNISC</b>	Universidade de Santa Cruz do Sul
<b>XCS</b>	<i>eXtended Classifier System</i>
<b>ZCS</b>	<i>Zeroth Level Classifier System</i>

## SUMÁRIO

LISTA DE FIGURAS.....	5
LISTA DE TABELAS E QUADROS.....	6
LISTA DE ABREVIATURAS.....	7
1 INTRODUÇÃO.....	10
2 FUNDAMENTAÇÃO TEÓRICA.....	13
2.1 Mercado de Capitais.....	13
2.2 Análise Fundamentalista.....	14
2.3 Análise Técnica.....	14
2.3.1 Médias móveis.....	16
2.3.2 Linhas de suporte e resistência.....	17
2.3.3 Índice de força relativa.....	18
2.3.4 Moving average convergence/divergence (MACD).....	19
2.4 Estratégias de Negociação.....	20
2.4.1 Otimização por Enxame de Partículas.....	21
2.4.2 Redes Neurais Artificiais (RNA).....	21
2.4.3 Extreme Learning Machines (ELM).....	23
2.4.4 Programação Genética.....	24
2.4.5 eXtended Classifier Systems (XCS).....	25
2.5 Trabalhos Relacionados de Estratégias de Negociação em Mercados de capitais.....	26
2.5.1 Stock trading rule discovery with an evolutionary trend following model..	26
2.5.2 A hybrid stock trading framework integrating technical analysis with machine learning techniques.....	27
2.5.3 Evolving intraday foreign exchange trading strategies utilizing multiple instruments price series.....	28
2.5.4 An adaptive stock index trading decision support system.....	29
2.5.5 Quadro Comparativo das Estratégias de Negociação no Mercado de Capitais.....	29
3 SISTEMA NEGOCIADOR BASEADO EM ABORDAGEM HÍBRIDA PARA O MERCADO DE CAPITAIS.....	33
3.1 Metodologia da Pesquisa.....	33
3.2 Arquitetura do Sistema Negociador.....	34
3.2.1 Indicadores.....	35
3.2.2 Base de Classificadores.....	37
3.2.3 Programação Genética.....	39
3.2.4 XCS.....	40
3.2.4.1 Aprendizado de máquina.....	41
3.2.4.2 Subsunção.....	41



3.2.4.3 Gerência de população .....	42
3.2.5 Sinais de Negociação.....	42
3.2.6 Recompensas .....	43
3.3 Carregamento do sistema negociador na plataforma MetaTrader 5 .....	43
4 RESULTADOS E DISCUSSÕES .....	47
4.1 Metodologia de Avaliação .....	47
4.2 Resultados .....	49
4.3 Discussões .....	52
5 CONCLUSÃO .....	54
REFERÊNCIAS .....	57

## 1 INTRODUÇÃO

Nos últimos anos, o mercado financeiro brasileiro experimentou um significativo crescimento, como um mercado de intermediação bancária ou de extensão de crédito. Desde o início dos anos 2000, a relação crédito privado/PIB (Produto Interno Bruto) avançou de pouco mais de 30% para cerca de 50% em junho de 2012 (IBMEC, 2016). Assim, o Mercado de Capitais se constitui em uma importante opção de investimento para pessoas e instituições, além de ser um canal fundamental na captação de recursos que permite o desenvolvimento das empresas, gerando empregos e contribuindo para o crescimento do País (IBMEC, 2016).

Os maiores mercados de ações ao redor do mundo possuem um volume de operações consideravelmente alto, o que justifica o interesse dos investidores na área de automatização de operações, buscando ao mesmo tempo maior lucratividade e segurança (GIACOMEL, 2016).

Neste contexto, a automatização das negociações baseada no histórico de preços de um ativo pressupõe a existência de uma previsibilidade dos valores futuros, e esta previsibilidade é possível de ser identificada por um algoritmo, por exemplo. Para a tomada de decisão no mercado de ações, utiliza-se análise técnica e análise fundamentalista. O estudo da análise técnica permite a utilização de indicadores de diversos tipos para identificar pontos de entrada e de saída do mercado de ações. Segundo Park e Irwin (2004), os principais tipos de indicadores técnicos são as médias móveis, canais de suporte e resistência, osciladores e filtros. Porém, existem incontáveis formas de implementar estes indicadores e de interpretá-los, como pode ser observado em Neely e Weller (2011). A análise fundamentalista, por outro lado, busca identificar os motivos pelos quais o preço de uma ação se direcionará no futuro, com base em análises de risco, expectativas econômicas e notícias a respeito do setor (CHAVES, 2004).

O mercado acionário, sendo um canal fundamental que permite o desenvolvimento de empresas, gerando novos empregos e contribuindo para o progresso do País, através da captação de recursos com a realização de uma oferta pública de ações, também é uma importante opção de investimento para pessoas e instituições (BM&F BOVESPA, 2010).

Serve como justificativa social o fato de que é pela participação de novos sócios (os acionistas), durante a OPA (Oferta Pública de Ações), que uma empresa ganha condição de obter novos recursos não exigíveis, como contrapartida à participação no seu capital. Assim, com os recursos necessários, as empresas têm condições de investir em novos equipamentos

ou no desenvolvimento de pesquisas, melhorando seu processo produtivo, tornando-o mais eficiente e beneficiando toda a comunidade. Este processo de capitalização das empresas só é possível devido à liquidez proporcionada pelo mercado de capitais, que é um sistema de distribuição de valores mobiliários (BM&F BOVESPA, 2010).

Como justificativa científica para este trabalho, pode-se citar os estudos que foram realizados na área de Inteligência Artificial, a fim de desenvolver o sistema negociador. Os resultados deste trabalho podem incentivar novas pesquisas nesta área do conhecimento. Técnicas de Inteligência Artificial são apoiadoras em processos de tomada de decisão por manipularem o conhecimento do domínio de forma explícita nos modelos desenvolvidos. Assim, utilizar tais técnicas no domínio do mercado de ações contribui com uma proposta que possa otimizar este processo e atingir melhores resultados quanto à decisão de compra e venda.

Assim, define-se como problema de pesquisa: “Como uma estratégia de negociação, baseada em técnicas de Inteligência Artificial, que utiliza indicadores, pode auxiliar na decisão em relação às operações de compra e venda de ativos no mercado de capitais?”.

O objetivo principal foi desenvolver uma estratégia de negociação, baseada em técnica de Inteligência Artificial, utilizando indicadores que possibilitassem a decisão em relação à compra ou venda de ativos em mercado de capitais.

Sendo assim, atingiu-se os seguintes objetivos específicos:

- Estudar a análise técnica e fundamentalista com o objetivo de determinar a abordagem mais adequada para este trabalho.
- Analisar outros trabalhos que utilizam tanto a análise técnica quanto a fundamentalista, aliada a técnicas de Inteligência Artificial, com o objetivo de elaborar um quadro comparativo de técnicas de Inteligência Artificial, estratégias de negociação, assim como os indicadores utilizados.
- Desenvolver o sistema negociador (estratégia de negociação), com a técnica de Inteligência Artificial escolhida após os estudos e análises.
- Validar a estratégia desenvolvida através de sua aplicação em dados históricos do ativo PETR4 na BM&F Bovespa.

O texto está organizado nos seguintes capítulos: no capítulo 2, é apresentada a fundamentação teórica, descrevendo os principais conceitos sobre mercado de capitais, estratégias de negociação e, por fim, os trabalhos relacionados; o capítulo 3 descreve a

metodologia e o sistema desenvolvido; o capítulo 4 apresenta os resultados obtidos e comparações com outros trabalhos; ao final, no capítulo 5, é apresentada a conclusão.

## 2 FUNDAMENTAÇÃO TEÓRICA

A revisão de literatura abordada nesta pesquisa está dividida em quatro tópicos: Mercado de capitais, Análise Fundamentalista, Análise Técnica e Estratégias de Negociação. Por fim, apresentam-se as sínteses e o quadro comparativo dos trabalhos relacionados.

### 2.1 Mercado de Capitais

Constituído por bolsas, corretoras e diversas instituições financeiras, o mercado de capitais é um sistema de distribuição de valores mobiliários, com o objetivo de viabilizar o processo de capitalização de empresas e dar liquidez aos títulos emitidos por elas (BM&F BOVESPA, 2010).

Os dois principais tipos de títulos negociados no mercado de capitais são os que representam o capital das empresas (ações) e os que representam empréstimos tomados através do mercado por estas empresas (debêntures conversíveis em ações, bônus de subscrição e *commercial papers*), que permitem a circulação de capital para custear o desenvolvimento econômico. Além destes títulos, o mercado de capitais comporta ainda negociações com direitos de subscrição de valores mobiliários, recibos de subscrição de valores mobiliários, certificados de depósitos de ações e outros derivativos (BM&F BOVESPA, 2010).

A maioria das operações realizadas no mercado de capitais tem caráter de longo prazo e podem ser realizadas por pessoas físicas e jurídicas. Para proteger os interesses dos investidores (pessoas físicas e jurídicas), todas as empresas participantes do mercado, e as operações realizadas no mesmo são fiscalizadas e regulamentadas pela Comissão de Valores Mobiliários (CVM) (LOPES, FIGUEIREDO E BUOSI, 2014).

A CVM é uma autarquia federal vinculada ao Ministério da Fazenda, porém sem subordinação hierárquica. Dentre os papéis desempenhados pela CVM, estão: evitar fraudes ou manipulações que criem condições artificiais de oferta e demanda, assegurar o acesso do público às informações relevantes sobre os valores mobiliários, e proteger investidores e titulares de valores mobiliários contra emissões irregulares de papéis, atos ilegais de administradores e acionistas controladores de companhias abertas, e uso de informação relevante não divulgada no mercado de valores mobiliários, entre outros (PORTAL DO INVESTIDOR, 2016).

Além de regular as negociações realizadas no mercado, a CVM define também as regras que devem ser seguidas por todas as empresas de capital aberto, auditores independentes, administradores de carteiras de valores mobiliários, agentes autônomos, fundos de investimento, corretoras, bancos de investimento e outras instituições (PORTAL DO INVESTIDOR, 2016).

## **2.2 Análise Fundamentalista**

Muitos trabalhos na área de análise fundamentalista já examinaram a associação existente entre os demonstrativos financeiros e o retorno futuro de ações (GOODMAN, NEAMTIU e ZHANG, 2012). Normalmente, a motivação por trás desta linha de raciocínio é que as informações contidas nestes demonstrativos estão ligadas à expectativa de lucro futuro das empresas, e que investidores não se baseiam apenas nos valores das ações para tomarem suas decisões, pois se baseiam também nas informações contábeis disponíveis.

Segundo Chaves (2004), análise fundamentalista é o estudo dos fatores que afetam a oferta e a demanda de um determinado mercado, com o objetivo de determinar o valor intrínseco de um ativo. A análise de uma empresa geralmente exige grande quantidade de informações, como por exemplo: balanços contábeis e demonstrações de resultados. A análise destes dados exige conhecimento técnico na área de contabilidade e administração de empresas, e portanto não é uma tarefa trivial para o cidadão comum.

No trabalho de Abad, Thore e Laffarga (2004), é demonstrado como a análise fundamentalista depende também de dados subjetivos para realizar a avaliação de empresas, citando estudos empíricos que avaliam declarações financeiras das empresas para prever os lucros futuros.

## **2.3 Análise Técnica**

A partir do século XVIII, famílias japonesas passaram a acompanhar as variações dos preços do arroz, com o objetivo de identificar tendências futuras do preço para tais oscilações. A forma como estas famílias realizavam este acompanhamento é considerada uma forma primitiva de análise técnica, e passou a ser conhecido posteriormente como *Candlesticks* (VIDOTTO, MIGLIATO e ZAMBON, 2009). Muitos indicadores de análise técnica se baseiam na utilização dos *candles* (apesar de existirem outras representações), que

demonstram o valor de abertura, de fechamento e o valor máximo e mínimo para o período, como pode ser visto na Figura 1.

Segundo Blume, Easley e O'Hara (1994), a análise técnica de dados vem sendo utilizada a tempos nos mercados de capitais. O autor ainda afirma que analistas técnicos acreditam que as informações sobre o preço e o volume de negociação de um ativo servem como indicadores do preço futuro do mesmo, e que examinando estes dados é possível identificar os movimentos por trás da precificação de um ativo. Segundo Muller e Frozza (2010), a utilização de análise técnica no mercado de ações teve origem a partir da “Teoria Dow”, criada por Charles Dow no começo do século XX, que buscava identificar tendências significativas de alta ou de baixa no mercado.




Figura 1 – *Candles* de baixa e de alta.

Fonte: (CHAVES, 2004)

Conforme Marshall *et al* (2008) *apud* Urquhart *et al.* (2015), investidores colocam mais ênfase na utilização de análise técnica para realizar previsões no curto prazo, e chegam a dar o dobro de prioridade para a utilização da mesma para operações *intraday* em relação às operações com prazo de um ano.

No trabalho de Muller e Frozza (2010), são descritos alguns exemplos de métodos utilizados em análise técnica, como Ondas de Elliott, análise de gráficos com formação de figuras, análise de gráficos de *candlesticks* e indicadores estatísticos. Nas próximas seções são descritos os principais indicadores encontrados na literatura sobre análise técnica.

### 2.3.1 Médias móveis

As médias móveis são um dos indicadores mais simples e uma das técnicas mais populares do mercado, segundo Wong, Manzur e Chew (2003). O valor deste indicador é obtido calculando o valor médio do ativo nos últimos  $n$  dias. Para realizar este cálculo pode-se utilizar o valor de fechamento ou de abertura, sendo mais utilizado o de fechamento.

O trabalho de Achelis (2000) descreve a interpretação deste indicador: quando o valor do ativo está acima do valor da média móvel, é uma indicação de tendência de alta, e vice-versa quando o valor estiver abaixo da média móvel. Como pode ser visto na Figura 2, este indicador não possui bons resultados quando o ativo está sem tendência, pois pode gerar muitos falsos sinais de compra e venda. Uma das maneiras de mitigar este problema é realizar abertura de posições apenas quando o valor do ativo ultrapassa a média móvel com uma certa margem, desta forma o lucro por operação pode ser levemente reduzido em troca de menos sinais falsos.

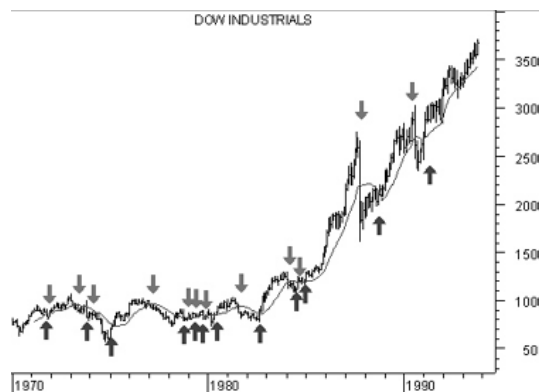


Figura 2 – Média móvel aplicada ao ativo Dow Industrials entre os anos 1970 e 1993.

Fonte: (ACHELIS, 2000)

Variações deste indicador, conforme Brock, Lakonishok e LeBaron (1992), Achelis (2000) e Wong, Manzur e Chew (2003) são:

- **Dupla Média Móvel:** este indicador utiliza duas médias móveis, uma de curto período (média rápida) e outra de longo período (média lenta). Os sinais de compra são gerados quando a média rápida corta a média lenta de baixo para cima, e vice-versa para os sinais de venda;
- **Tripla Média Móvel:** utiliza três médias móveis, uma de curto período (rápida), uma de médio período (média) e uma de longo período (lenta). Neste indicador, a rápida e a média



funcionam exatamente igual a dupla média móvel, porém sinais de compra são gerados apenas quando o cruzamento da média e da rápida ocorre acima da lenta. Quando a rápida corta a média de cima para baixo, isto indica apenas um fechamento da posição de compra;

- Média Móvel Exponencial: esta é uma variação da média móvel simples. A diferença está no fato de que as barras mais recentes possuem peso maior no cálculo da média móvel exponencial. Este peso maior para valores mais recentes faz com que sinais sejam gerados com menor latência do que as médias simples;
- Média Móvel Adaptativa: este indicador foi criado com base na média móvel exponencial. A diferença entre os dois é que a adaptativa considera a variação recente no valor do ativo para determinar o peso aplicado aos valores mais recentes no cálculo da média. Assim, a média móvel adaptativa é mais resistente a ruídos, ou variações bruscas no valor do ativo, evitando gerar falsos sinais.

### 2.3.2 Linhas de suporte e resistência

O trabalho de Curcio e Goodhart (1992) define suporte como a linha abaixo do preço do ativo, onde a força compradora sobrepõe a força vendedora, fazendo com que o valor do ativo pare de cair, enquanto que a linha de resistência é definida como a linha acima do preço do ativo onde a força vendedora sobrepuja os compradores, fazendo com que o valor do ativo pare de subir. Na Figura 3 é possível observar tanto as linhas de suporte e resistência, quanto as respectivas inversões de movimento do preço do ativo Dólar Mini negociado na BOVESPA.




Figura 3 – Linhas de suporte e resistência no gráfico semanal do contrato de Dólar Mini.

Fonte: (AUTORES, 2016)

Em Kavajecz e Odders-White (2002), é demonstrada uma maneira de identificar as linhas de suporte e resistência de um ativo com base nas ordens colocadas no livro de ofertas. O autor sugere que os preços onde o ativo possui maior número de ordens formem barreiras ao avanço dos preços, fazendo com que a tendência do ativo perca força ou inverta.

### 2.3.3 Índice de força relativa

O Índice de Força Relativa, ou do inglês *Relative Strength Index* (RSI), segundo Achelis (2000) é um oscilador de momento criado por Welles Wilder em 1978 que determina a força no movimento de um ativo em relação ao seu histórico recente. É comumente utilizado para identificar reversões no valor de um ativo, quando este começa a perder seu momento após um período de frequentes altas ou baixas. Este indicador possui valores entre 0 e 100, onde valores acima de 50 indicam maior força compradora (representada por altas recentes no valor do ativo) e valores abaixo de 50 indicam maior força vendedora. Quando o RSI foi criado, Wilder sugeria a utilização do período de 14 dias no cálculo do indicador, mas desde então períodos entre 9 e 25 dias ganharam popularidade, sendo que períodos menores deixam o indicador mais volátil.

No trabalho de Wong, Manzur e Chew (2010), são definidas quatro maneiras de utilizar este indicador:

- *Touch*: este método gera um sinal de compra quando o RSI toca a linha inferior (normalmente definida em 30), o que normalmente indica um mercado sobrevendido, e portanto uma oportunidade de compra. Um sinal de venda é gerado similarmente quando o indicador toca a linha superior (normalmente definida em 70);
- *Peak*: este método gera um sinal de compra quando o indicador já ultrapassou a linha inferior, mas começou a subir, formando um vale no gráfico. Da mesma maneira, ele gera um sinal de venda quando o indicador já ultrapassou a linha superior mas começou a cair, formando um pico no gráfico;
- *Retracement*: gera um sinal de compra quando o RSI já atravessou a linha inferior e volta a cruzar a linha inferior para cima. Similarmente, cria sinal de venda quando o RSI está acima da linha superior e atravessa ela para baixo;
- *50 Crossover*: gera um sinal de compra quando o indicador atravessa para cima a linha central (definida em 50) e um sinal de venda quando o indicador a atravessa para baixo. Diferente dos outros métodos que são utilizados como indicadores de “contra-tendência”,

identificando reversões no valor do ativo, este método é mais efetivo para identificar inícios de tendência.

Na Figura 4 são demonstrados exemplos de sinais de compra e venda gerados pelo indicador RSI, quando aplicado o método “*Retracement*”.




Figura 4 – Sinais do indicador RSI de 12 dias no gráfico diário do ativo PETR4.

Fonte: (AUTORES, 2016)

### 2.3.4 *Moving average convergence/divergence* (MACD)

Criado em 1979, por Gerald Appel, o *Moving Average Convergence/Divergence* (MACD) indica tendências no movimento do preço do ativo com base na convergência ou divergência de médias móveis sobre um determinado ativo (OSÓRIO, 2010). Para utilizar este indicador, é necessário calcular a diferença entre duas médias móveis exponenciais sobre o ativo, uma lenta (normalmente com período de 26 dias) e uma rápida (normalmente com período de 12 dias), esta diferença é normalmente chamada de linha MACD. Então, sobre esta diferença é aplicada uma média móvel exponencial (normalmente com período de 9 dias), normalmente chamada de linha de sinal.

Segundo Viddoto, Migliato e Zambon (2009), os sinais de compra são gerados quando a linha de sinal ultrapassa a linha MACD para cima, indicando uma tendência de alta no ativo, enquanto sinais de venda são criados quando a linha de sinal ultrapassa para baixo a linha

MACD. Apesar de os períodos mais comuns serem os de 12, 26 e 9 dias para a média rápida, lenta e linha de sinal respectivamente, outros valores são possíveis. Um exemplo dos sinais gerados por este indicador pode ser observado na Figura 5.




Figura 5 – Sinais do indicador MACD no gráfico diário do ativo PETR4.

Fonte: (AUTORES, 2016)

## 2.4 Estratégias de Negociação

No trabalho de Hu *et al* (2015b), realizaram um estudo do estado da arte em relação à aplicação de computação evolutiva nos mercados de capitais. Foram analisados 51 artigos de 24 *journals* e classificados em três grupos conforme a abordagem utilizada: algoritmos evolucionários, inteligência de enxame e técnicas híbridas de computação evolutiva. Foi observado que muitos trabalhos tendem a utilizar técnicas para descobertas de regras de negociação baseadas em análise técnica através de algoritmos genéticos e programação genética. Todos os trabalhos analisados estão disponíveis no site *ResearchGate*<sup>1</sup>.

Além das técnicas evolucionárias, observou-se também que muitos autores preferem abordagens envolvendo Redes Neurais Artificiais (RNA) e algumas variantes, como, por

<sup>1</sup> <https://www.researchgate.net>

exemplo, a *Extreme Learning Machine* (ELM). Nesta seção são apresentadas as principais estratégias de negociação utilizadas para construção de sistemas negociadores em mercados de capitais.

#### 2.4.1 Otimização por Enxame de Partículas

Proposta em Kennedy e Eberhart (1995), a Otimização por Enxame de Partículas, ou do inglês *Particle Swarm Optimization* (PSO), foi criada com o intuito de produzir comportamento inteligente através da exploração de análogos à interação social no reino animal. A inspiração para tal técnica veio da observação de pássaros voando em bandos à procura de alimento em plantações de milho.

Segundo Poli, Kennedy e Blackwell (2007), na PSO, partículas são dispostas aleatoriamente sobre o espaço de busca do problema, e cada uma destas partículas calcula o valor de sua função objetivo (ou heurística) no seu local atual. Cada partícula determina então uma direção de movimento, com base na melhor localização que a partícula já esteve e na melhor localização global (dentre todas as partículas) e mais algum fator aleatório. Este ciclo é repetido, e a cada iteração, o enxame como um todo, tende a se mover para um ótimo global, com base na heurística adotada, ou função objetivo.

Uma das principais características da PSO é a exploração do espaço de buscas de maneira a evitar máximos locais, fazendo desta técnica um método interessante para a inicialização dos pesos de Redes Neurais Artificiais de maneira a evitar a convergência para um máximo local, como demonstrado em Chiang *et al* (2016). Segundo Kennedy e Eberhart (1995), esta técnica possui grandes semelhanças com computação evolutiva, uma vez que a otimização acontece de maneira semelhante à função de *crossover* dos algoritmos genéticos, e devido à utilização de uma função heurística de *fitness*, assim como todos os paradigmas de computação evolutiva.

#### 2.4.2 Redes Neurais Artificiais (RNA)

A inspiração para a criação de Redes Neurais Artificiais (RNA), vem da capacidade de aprendizagem existente no cérebro humano, fazendo com que pesquisadores desenvolvessem modelos artificiais que simulam o comportamento do neurônio biológico (HAYKIN, 1999).

Em McCulloch e Pitts (1943) *apud* Russel e Norvig (2010), foi proposto o primeiro modelo matemático de um neurônio. Este modelo é dividido em 3 partes: Função de entrada,

Função de ativação e Saída, como pode ser observado na Figura 6. A função de entrada em geral é uma função de soma ( $\Sigma$ ), que realiza o somatório do produto entre todas as entradas do neurônio ( $a_i$ ) e seus respectivos pesos ( $w$ ). A função de ativação ( $f$ ) recebe a saída da função de entrada e determina se este neurônio será ativado ou não pelas entradas recebidas, normalmente sendo utilizada para esta tarefa uma função de escada, sigmóide ou linear (HAYKIN, 1999). A saída da função de ativação é a saída do neurônio ( $a_j$ ), que é passada posteriormente como entrada para outros neurônios em camadas posteriores.




Figura 6 – Modelo matemático do neurônio de McCulloch e Pitts.

Fonte: (RUSSEL e NORVIG, 2010)

Uma RNA é formada quando múltiplos neurônios são interconectados através de camadas. Uma RNA possui no mínimo duas camadas: uma de entrada, que representa os estímulos do ambiente ou as variáveis de algum problema e uma camada de saída que representa a ação tomada ou a solução para o problema. Porém, uma rede pode possuir inúmeras camadas intermediárias (ou ocultas), que podem aumentar a capacidade de aprendizado da rede (HAYKIN, 1999).

Segundo Russel e Norvig (2010), o aprendizado em RNAs ocorre através de um processo chamado Regressão Logística, onde os pesos da rede são ajustados de maneira que as saídas da rede reflitam os exemplos apresentados durante o seu treinamento. O método mais comum para realizar este treinamento é através do *backpropagation*, onde os pesos são ajustados conforme o erro existente na saída da rede, com base nos exemplos apresentados. Este erro é utilizado para ajustar os pesos da camada de saída e depois é retro propagado para as camadas anteriores, sendo utilizado para ajustar os pesos daquelas camadas.

Em mercados financeiros ao redor do mundo, as estratégias envolvendo RNAs estão entre as mais populares dentre os investidores, devida a sua capacidade de identificar padrões em séries temporais (GIACOMEL, 2016).

#### 2.4.3 *Extreme Learning Machines (ELM)*

Proposta em Huang, Zhu e Siew (2004), a *Extreme Learning Machine (ELM)* é uma RNA do tipo *feedforward* com uma camada oculta, que utiliza um algoritmo de aprendizagem não iterativo, diferente do *backpropagation*. Assim, este tipo de rede possui como característica um aprendizado rápido, sendo necessária apenas uma iteração pelo conjunto de treinamento. Segundo os autores, além da vantagem da velocidade do aprendizado, o método de aprendizagem da ELM não depende de uma função de ativação diferenciável (como é o caso do *backpropagation*), e é menos suscetível a ter problemas com mínimos locais, *overfitting* e taxas de aprendizado inapropriadas. O aprendizado proposto define aleatoriamente os pesos de entrada da camada oculta e depois escolhe de forma analítica os pesos da camada de saída, através da Inversa Generalizada de Moore-Penrose e da Solução Geral de Sistemas Lineares por Mínima Norma e Mínimos Quadrados.

Em Huang, Zhu e Siew (2006), são realizadas comparações entre ELM, *backpropagation* (BP) e *Support Vector Machine for Regression* (SVR). Para simular um caso artificial, foi utilizado o problema da aproximação da função *SinC*, comumente utilizado na literatura para ilustrar SVRs. No conjunto de treinamento, com 5000 pontos, utilizado na avaliação foi adicionada uma grande quantidade de ruído uniformemente distribuído, o conjunto utilizado para testes não possui ruído. Calculando a média de 50 execuções, os dados da Tabela 1 foram obtidos, e como pode-se observar, a solução ELM possui um tempo de treinamento consideravelmente menor com desempenho pouco superior à utilização de BP ou SVR.

**Tabela 1 – Desempenho comparado entre ELM, BP e SVR para o problema *SinC*.**

Algoritmos	Tempo (s)		Treinamento		Testes (avaliação)	
	Treino	Testes	Erro quadrático médio	Desvio padrão	Erro Quadrático Médio	Desvio padrão
<b>ELM</b>	0,125	0,031	0,1148	0,0037	0,0097	0,0028
<b>BP</b>	21,26	0,032	0,1196	0,0042	0,0159	0,0041
<b>SVR</b>	1273,4	5,9087	0,1149	0,0007	0,0130	0,0012

Fonte: (HUANG, ZHU e SIEW, 2006)

No trabalho de Tang, Deng e Huang (2016), é demonstrado como a técnica de aprendizado das ELMs pode ser aplicada em uma RNA do tipo *Multilayer Perceptron*, com a finalidade de aplicação em problemas de visão computacional, superando assim a limitação original da ELM de possuir apenas uma camada oculta. Os autores propõem uma estrutura hierárquica de treinamento, nomeada H-ELM, separada em duas fases: representação não-supervisionada de características hierárquicas, e classificação supervisionada de características hierárquicas. Os resultados apresentados, comparados com outras técnicas de visão computacional, são promissores, tanto quanto ao tempo de execução, quanto à capacidade de aprendizado.

#### 2.4.4 Programação Genética

Inspirado nos processos evolutivos existentes na natureza, John Holland descreveu como tais processos poderiam ser empregados em sistemas artificiais através da aplicação de algoritmos genéticos sobre vetores de caracteres de tamanho fixo (KOZA, 1991). Holland demonstrou como uma população destes vetores, chamados de cromossomos, representando modelagens de problemas poderiam evoluir através do processo de seleção natural Darwiniano, utilizando operações de *crossover* (reprodução entre dois indivíduos onde ocorre a troca de elementos do cromossomo) e mutação (operação que altera elementos do cromossomo de forma aleatória). A seleção natural ocorre permitindo que os indivíduos com maior *fitness* (uma função de avaliação empregando uma heurística no domínio do problema) tenham maiores chances de se reproduzir.

Em Koza (1992) *apud* Luke e Spector (1998), o trabalho de Holland é estendido através da Programação Genética (PG), onde o problema é resolvido pela criação de um programa gerado evolutivamente através dos conceitos de algoritmos genéticos. Este programa é representado por uma estrutura de árvore (o cromossomo) onde os nós intermediários da árvore são funções (lógicas e aritméticas) e os nós folhas são constantes e variáveis. A operação de *crossover* neste caso faz com que subárvores inteiras dos indivíduos reprodutores sejam substituídas, enquanto a operação de mutação pode remover, incluir ou alterar subárvores do indivíduo sofrendo a mutação.

No trabalho de Potvin, Soriano e Vallée (2004), é demonstrado um exemplo de aplicação do conceito de Programação Genética no mercado acionário canadense. A abordagem proposta pelo autor codifica regras de negociação com base nos preços do ativo e



em indicadores técnicos nos indivíduos da população. Nesta modelagem, os nós intermediários da árvore podem ser operações lógicas ( $<$ ,  $>$ , *and*, *or* e *not*), aritméticas ( $+$ ,  $-$ ,  $/$ ,  $*$ ), funções (*abs*, *avg*, *max*, *min*, *lag*, *volatility*) e funções de indicadores (RSI e *Rate of Change*), enquanto os nós folhas são constantes, volumes ou preços de fechamento do ativo. Na Figura 7 pode-se observar um exemplo de indivíduo representando uma regra onde um sinal de compra é gerado caso o preço médio dos últimos 50 dias seja maior que o preço atual ou se o volume for menor que 20.




Figura 7 – Indivíduo representando uma regra de negociação.

Fonte: (POTVIN, SORIANO e VALLÉE, 2004)

#### 2.4.5 *eXtended Classifier Systems (XCS)*

Segundo Hu *et al.* (2015a), o *Learning Classifier Systems (LCS)* foi proposto nos trabalhos de John Holland em 1976, e consiste em aplicar os conceitos de aprendizagem de máquina, algoritmos genéticos e outras heurísticas para criar um sistema adaptativo. Porém, o sistema proposto por Holland era demasiado complexo e de difícil modelagem, o que levou Wilson (1994) a propor o “*Zeroth-level Classifier System (ZCS)*”, que buscava reduzir a complexidade do LCS original e aumentar seu desempenho, porém mantendo a essência dos trabalhos de Holland. Mais tarde, conforme descrito por Bull (2004), em 1995, Wilson propôs uma técnica superior ao ZCS em relação à capacidade de generalização dos problemas, chamado de *eXtended Classifier System (XCS)*, descrito em detalhe no trabalho de Butz *et al.* (2001).

Conforme Butz *et al.* (2001), o XCS age como um agente aprendendo, que percebe o estado atual do ambiente, responde selecionando uma ação e recebe uma recompensa como indicador do valor de sua ação. Quando o XCS percebe o ambiente, ele compara o estado deste a um conjunto de classificadores, contendo condições e ações a serem tomadas caso a condição seja satisfeita. A condição de cada classificador é um vetor ternário, podendo ter em cada posição os valores “0”, “1” ou “#”, onde “#” é um coringa, que vale tanto como “0” ou “1” ao verificar se a condição do classificador é satisfeita. Caso nenhum classificador case com o ambiente percebido, novos classificadores são criados em um processo chamado de *covering*, onde o estado do ambiente é utilizado para gerar uma regra com ação aleatória. Os classificadores que casarem com o estado do ambiente são separados em um conjunto de ação. Em cada ciclo, o XCS atualiza as regras que estiverem no conjunto de ação, com base na recompensa recebida. Regras que não estiverem no conjunto de ação não são atualizadas. Além disso, a cada ciclo existe uma chance de aplicação de um algoritmo genético sobre as regras do conjunto de ação, selecionando dois classificadores com base em um *fitness*, como ocorre normalmente em algoritmos genéticos. Os pais selecionados para reprodução são mantidos na população de regras para competir com os filhos gerados. Segundo os autores, uma diferença chave entre o XCS e seus predecessores é o fato de que o XCS mantém estimativas separadas de utilidade de um classificador para a seleção de ação e para reprodução. Finalmente, um procedimento de deleção por subsunção ocorre caso um classificador possua regra mais genérica, experiente e acurada que algum outro classificador da população, simplificando assim o conjunto de regras.

## **2.5 Trabalhos Relacionados de Estratégias de Negociação em Mercados de capitais**

Nesta seção, é apresentada uma análise comparativa das principais características de alguns trabalhos selecionados, dedicados ao estudo de Estratégias de negociação em Mercados de Capitais, compreendendo: objetivo, tipo de análise, técnicas de negociação utilizadas, dados utilizados e resultados.

### **2.5.1 Stock trading rule discovery with an evolutionary trend following model**

No trabalho de Hu *et al.* (2015a), foi proposto um algoritmo evolucionário híbrido unindo tendências de longo e curto prazo, apelidado de *eTrend*. Especificamente, os autores utilizam o *eXtended Classifier System* (XCS) como estratégia evolucionária para encontrar

regras de negociação que definam pontos de entrada nos ativos, baseadas em 7 indicadores técnicos de volume e de tendências de curto prazo. Integrado ao XCS, são utilizadas médias móveis de longo prazo para determinar se o mercado está em uma tendência de alta ou de baixa. A estratégia adotada é capaz de se adaptar à situação do mercado, independentemente do tipo de tendência que está ocorrendo. A validação da estratégia foi realizada utilizando dados do Mercado de ações de Shangai entre janeiro de 2001 e julho de 2013, sobre três índices populares: *Composite Index*, *Industrial Index* e *Business Index*. Para realizar esta validação, foi utilizada uma janela deslizante, sempre utilizando o ano anterior como treinamento para o ano corrente. A solução proposta superou a estratégia de *Buy-and-Hold* nos três ativos analisados, com retornos anuais cerca de 10% superiores e com alto índice de Sortino. Para comparação com outros algoritmos, o XCS foi substituído por uma RNA e por uma Árvore de Decisão, e em ambos os cenários o desempenho foi inferior ao XCS. As limitações encontradas pelos pesquisadores é de que as estratégias de negociação selecionadas da indústria deixam a desejar, o que pode levar a crer que as regras descobertas pelo *eTrend* não são ótimos globais. Em trabalhos futuros, o *eTrend* pode ser melhorado através de uma abordagem evolucionária mais sofisticada e através da inclusão de mais conhecimento de especialistas como entrada do algoritmo de aprendizagem.

### **2.5.2 A hybrid stock trading framework integrating technical analysis with machine learning techniques**

No trabalho de Dash e Dash (2016), é proposto um sistema de suporte à tomada de decisão utilizando *Computational Efficient Functional Link Artificial Neural Network* (CEFLANN) e uma regra de aprendizado baseada em *Extreme Learning Machine* (ELM). O objetivo do trabalho é criar uma CEFLANN e um conjunto de regras baseadas em análise técnica para gerar as decisões de negociação de forma eficiente. Seis indicadores populares são calculados a partir do histórico do ativo negociado e são utilizados como entradas para o modelo proposto. Ao invés de utilizar um sinal de negociação discretizado para o treinamento da rede, um valor contínuo entre 0 e 1 é utilizado. A saída da CEFLANN é utilizada comparada com um indicador baseado em médias móveis desenvolvido pelo próprio autor para determinar se existe ou não uma oportunidade de compra ou venda. O sistema foi validado em 5 anos de dados históricos de dois índices: BSE SENSEX e S&P 500. Foram utilizadas barras diárias entre janeiro de 2010 e dezembro de 2014. Para realizar o treinamento foram utilizadas as primeiras 1000 barras (aproximadamente 4 anos) e as restantes foram

utilizadas para avaliar o desempenho. A solução proposta foi comparada a outras estratégias de negociação, como *Support Vector Machine*, *Naive Bayesian Model*, *K nearest neighbor model* e Árvore de decisão, obtendo lucros consistentes superior a todos em ambos os índices. Como trabalhos futuros, os autores sugerem a aplicação da técnica em outros conjuntos de dados e em cenários reais. Além disso eles pretendem estudar a otimização da estrutura do modelo através da utilização de Evolução Diferencial, Busca Harmônica e *Shuffled Frog Leaping Algorithm*, além de explorar melhor a análise técnica.

### **2.5.3 Evolving intraday foreign exchange trading strategies utilizing multiple instruments price series**

No trabalho de Cirillo, Lloyd e Nordin (2014), foi proposta uma arquitetura de Programação Genética (PG) para a generalização de estratégias de negociação no mercado de câmbio exterior, ou *Foreign Exchange* (FOREX). O sistema evolui estratégias que não dependem de modelagens anteriores e nem das séries temporais de múltiplos ativos financeiros. São utilizados os valores de abertura, fechamento, máxima e mínima em barras de 5 minutos de quatro pares de moedas: AUD/USD, EUR/USD, GBP/USD e USD/JPY. Apesar de serem considerados quatro pares de moedas durante o treinamento, o sistema foi avaliado apenas negociando o par USD/JPY. Cada indivíduo da população é uma árvore formada por variáveis (valores das barras e constantes) e funções (adição, subtração, multiplicação, divisão, seno, cosseno, tangente, *ifThenElse*, maior que, e menor que) que representam regras de negociação aprendidas. O sistema foi aplicado sobre 3 conjuntos de dados: um de treinamento (10 meses de dados com 87.603 barras), um de validação (2 meses, iniciando ao final do conjunto de treinamento, com 17.612 barras) e um terceiro fora da amostragem, utilizado para simular um cenário real (12 meses, iniciando ao final do conjunto de validação, com 105.759 barras). Durante o treinamento, os indivíduos avaliados contra os dados de treinamento obtiveram os melhores resultados (obviamente, uma vez que foram otimizados sobre estes mesmos dados), atingindo até 32% de lucro. Sobre os dados simulando um cenário real, a melhor estratégia atingiu 18% de lucro, mas em média os resultados obtidos pelos indivíduos da população variam entre 2% e 5%, deixando a desejar contra os 11% obtidos através da estratégia de *Buy-and-Hold*. Como trabalhos futuros os autores sugerem a utilização de conjuntos de treinamento e validação com tamanho igual, assim como avaliar a utilização das séries históricas de cada ativo durante o treinamento.

#### 2.5.4 An adaptive stock index trading decision support system

No trabalho de Chiang *et al.* (2016), foi desenvolvido um sistema de suporte à tomada de decisão adaptativo para negociação de índices de ações, utilizando uma RNA para prever o movimento futuro do valor dos ativos. O modelo desta RNA é adaptado para cada ativo, ao invés de buscar uma solução global genérica. Para inicializar os pesos da RNA de forma a evitar máximos locais durante seu treinamento, é utilizado um algoritmo de otimização por enxame de partículas. Para adaptar a RNA a um determinado ativo, são treinadas diversas combinações de entradas (dados de indicadores técnicos, volumes e valores do ativo) na RNA e é selecionada a que gerar melhores resultados. Todos os dados de entrada e saída são normalizados entre 0 e 1. Para cada teste, é utilizada uma janela deslizante, onde são utilizados dois anos de dados para treinar a rede e um ano para avaliá-la. A avaliação da solução foi realizada sobre diferentes tipos de ativos do mercado americano durante o ano de 2010, utilizando os dados entre 2008 e 2009 como treinamento. Os resultados atingidos foram satisfatórios, superando com diferentes níveis de sucesso a estratégia de *Buy-and-Hold*. Posteriormente, os autores perceberam que o número de sinais dado pelo sistema era muito elevado, devido ao ruído inerente de ativos do mercado de capitais. Para minimizar este efeito, uma remoção de ruído por *wavelets* foi utilizada, e depois o sistema foi testado novamente, obtendo lucros maiores com menor número de transações (menores custos operacionais). Em média, obtiveram 48% de lucro ao longo do ano, em comparação aos 18% obtidos pela estratégia *Buy-and-Hold*. Os autores veem como limitação o fato de que o sistema está restrito apenas à utilização de indicadores técnicos como entrada, e que tais indicadores possuem melhor desempenho em mercados com tendências definidas. Como trabalhos futuros são sugeridas: a aplicação do trabalho em outros tipos de ativos, em particular no mercado de moedas (*Foreign Exchange Market*); e a utilização de outros tipos de dados como entrada para a rede, como indicadores macroeconômicos; utilização de outros modelos, além da RNA do tipo *feedforward* com *Backpropagation*.

#### 2.5.5 Quadro Comparativo das Estratégias de Negociação no Mercado de Capitais

Esta seção apresenta um quadro comparativo (Quadro 1) dos trabalhos descritos nas seções anteriores.

**Quadro 1 – Quadro comparativo dos trabalhos relacionados – Estratégias de Negociação no Mercado de Capitais**

Trabalhos Relacionados	Objetivo	Tipo de Análise	Técnicas de negociação utilizadas	Dados utilizados	Resultados
(HU <i>et al.</i> , 2015a)	Propor um algoritmo evolucionário híbrido seguidor de tendências de curto e longo prazo.	Análise Técnica	XCS com 7 indicadores técnicos de volume e tendência de curto prazo, aliado a médias móveis de longo prazo.	3 Índices do mercado de ações de Shangai entre janeiro de 2001 e julho de 2013 (barras diárias).	Retornos anuais 10% superiores à estratégia de <i>Buy-and-Hold</i> com alto índice de Sortino.
(DASH e DASH, 2016)	Criar uma CEFLANN e um conjunto de regras baseadas em análise técnica para gerar decisões de negociação de forma eficiente.	Análise Técnica	CEFLANN com regra de aprendizado baseada em ELM, aliada a 6 indicadores técnicos.	5 anos de dados históricos dos índices BSE SENSEX e S&P 500 (barras diárias).	Obteve lucros superiores às estratégias comparadas: <i>Support Vector Machine</i> , <i>Naive Bayesian Model</i> , <i>K nearest neighbor model</i> e <i>Árvore de decisão</i> .
(CIRILLO, LLOYD e NORDIN, 2014)	Desenvolver uma estratégia independente de séries temporais para operar no mercado de câmbio FOREX.	Análise Técnica	Programação Genética	2 anos de dados históricos sobre 4 pares de moedas: AUD/USD, EUR/USD, GBP/USD e	A melhor estratégia atingiu 18% de lucro, mas em média os resultados obtidos pelos indivíduos da população variam entre 2% e 5%, contra os 11% obtidos

				USD/JPY (barras de 5 minutos).	através da estratégia de <i>Buy-and-Hold</i> .
(CHIANG <i>et al.</i> , 2016)	Desenvolver um sistema de suporte à tomada de decisão adaptativo para negociação de índices de ações.	Análise Técnica	RNA inicializada por um algoritmo de Otimização por Enxame de Partículas. Recebe como entradas indicadores técnicos, volumes e valores dos ativos.	Dados históricos de ativos do mercado americano entre 2008 e 2010 (barras diárias).	Em média, obtiveram 48% de lucro ao longo do ano avaliado, em comparação aos 18% obtidos pela estratégia <i>Buy-and-Hold</i> .

No Quadro 1, pode-se observar que todos os trabalhos implementados utilizaram análise técnica para o desenvolvimento de suas estratégias de negociação. Com exceção do trabalho de Cirillo, Lloyd e Nordin (2014), que obteve os piores resultados, todos os trabalhos utilizaram diversos indicadores técnicos na estratégia implementada. Mesmo sem a aplicação de indicadores técnicos, a abordagem com Programação Genética obteve lucros, levando a crer que a inclusão de indicadores possa melhorar o desempenho desta abordagem. O trabalho de Hu *et al.* (2015a) foi o que utilizou o maior conjunto de dados para treinamento e validação da estratégia, obtendo resultados positivos consistentes (indicados pelo índice de Sortino elevado). Em Chiang *et al.* (2016) foram obtidos os maiores lucros, porém, foi o trabalho validado no menor período, dentre os que utilizaram barras diárias, deixando dúvidas sobre a consistência da estratégia adotada.

Após estas análises realizadas, decidiu-se o desenvolvimento deste trabalho abordando a aplicação em análise técnica, com a estratégia de negociação baseada em programação genética e XCS (abordagem híbrida), utilizando os dados históricos de 5 anos (3 para validação utilizando uma janela deslizante de 2 anos para o aprendizado), referentes ao papel PETR4 na BM&F Bovespa. Optou-se pela abordagem híbrida para tentar melhorar os resultados de Cirillo, Lloyd e Nordin (2014), através da inclusão de indicadores técnicos e da abordagem com XCS de Hu *et al.* (2015a).



### 3 SISTEMA NEGOCIADOR BASEADO EM ABORDAGEM HÍBRIDA PARA O MERCADO DE CAPITAIS

Neste capítulo é apresentada a metodologia e a descrição das etapas de desenvolvimento do sistema negociador, baseado nos trabalhos de Hu *et al.* (2015a) e Cirillo, Lloyd e Nordin (2014), utilizando XCS (*eXtended Classifier Systems*) aliado à Programação Genética para atuação em mercados de capitais.

#### 3.1 Metodologia da Pesquisa

A pesquisa é de caráter exploratório e explicativo, já que são analisados trabalhos existentes e seus resultados e, a partir disso, são descritas as características envolvidas no domínio deste trabalho.

Quanto à coleta de dados, a pesquisa é de caráter bibliográfico, com busca de trabalhos em publicações no portal de periódicos da CAPES, *Web of Science* e *Scopus*. O objetivo foi coletar trabalhos para analisar as técnicas já desenvolvidas e as contribuições atingidas no domínio do mercado de ações.

Quanto aos procedimentos de coleta, é levantamento, com a busca dos principais indicadores técnicos do mercado financeiro utilizados na estratégia de negociação desenvolvida e base de dados para avaliar o seu desempenho em diferentes períodos de tempo.

A pesquisa é de caráter quantitativa quanto às variáveis utilizadas. São avaliados: quantidade de negociações vencedoras, quantidade de negociações perdedoras, lucro médio obtido por negociação, perda média obtida por negociação, *drawdown* máximo<sup>2</sup>, número de negociações, e lucro líquido ou perda líquida total. Também qualitativa quanto à avaliação da estratégia de negociação desenvolvida e utilizada.

Na Figura 8, podem ser observadas as etapas do desenvolvimento do sistema. Inicialmente, foram realizados os levantamentos bibliográficos e dos trabalhos relacionados. Com base nestes dados, foi definida a arquitetura do sistema (descrita na seção 3.2), e então se deu início ao desenvolvimento dos classificadores, do módulo de Programação Genética, e

---

<sup>2</sup> *Drawdown* máximo: Maior diferença entre o fundo de um vale e o último pico ocorrido no gráfico de saldo da carteira. É uma forma de medir o risco da estratégia utilizada.

dos módulos do XCS. Finalmente, foi realizada a calibragem dos parâmetros, testando diferentes configurações e depois, realizada a validação do sistema.

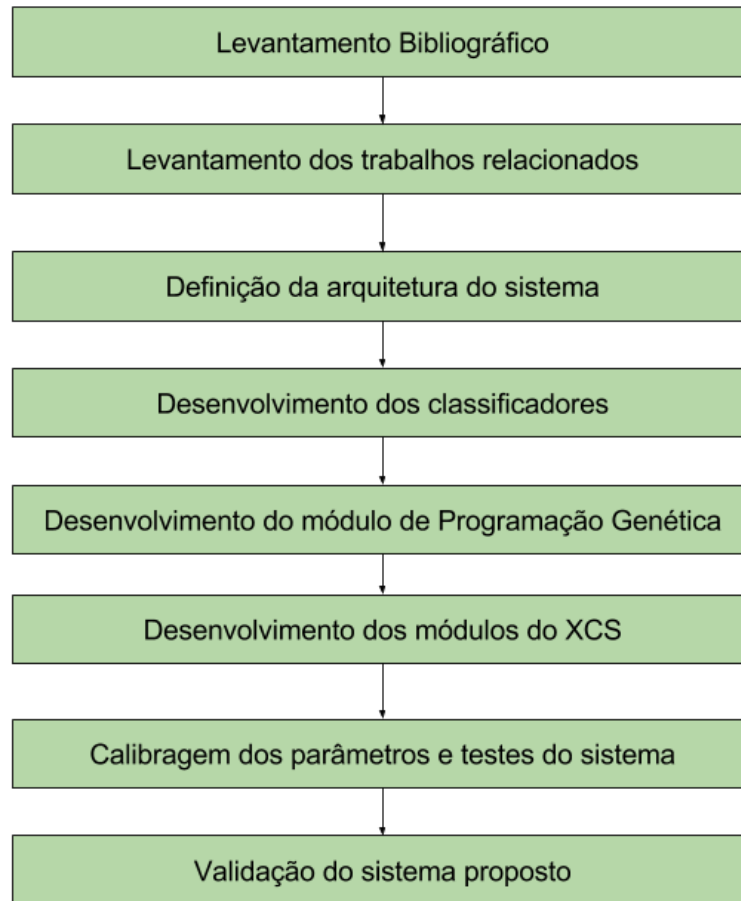


Figura 8 – Etapas do desenvolvimento.

Fonte: (AUTORES, 2016)

### 3.2 Arquitetura do Sistema Negociador

O sistema desenvolvido tem como objetivo a negociação de ativos individuais no mercado de capitais brasileiro. Optou-se pela negociação de ativos individuais, já que cada ativo possui comportamento próprio e que inclusive este comportamento muda ao longo do tempo, tornando mais difícil a construção de uma estratégia de negociação genérica o suficiente para atuar sobre diversos ativos simultaneamente. A escolha do mercado brasileiro se dá pelo menor risco envolvido na negociação de ativos na mesma moeda de origem. Caso a opção fosse pela negociação em mercados estrangeiros, a flutuação do câmbio afetaria os resultados obtidos pela ferramenta, aumentando assim o grau de risco da operação.

A arquitetura geral do sistema é composta por um *eXtended Classifier System* (XCS) responsável por gerar e manter uma base de classificadores que representam regras de negociação utilizando como entrada diversos indicadores técnicos e, gerando como saída, sinais de negociação indicando se uma posição deve ser aberta, fechada ou mantida (caso já exista). Cada classificador que participa de uma tomada de decisão recebe uma recompensa com base no resultado de sua decisão. Diferentemente do XCS tradicional, na condição dos classificadores, é utilizada uma árvore de decisão ao invés de um vetor de *bits* para a representação do ambiente. As árvores de decisão dos classificadores são evoluídas através de Programação Genética (PG), onde as operações de *crossover* e mutação substituem subárvores dos classificadores. Na Figura 9 pode ser observada esta arquitetura, e nas seções seguintes, cada elemento é descrito em detalhe.

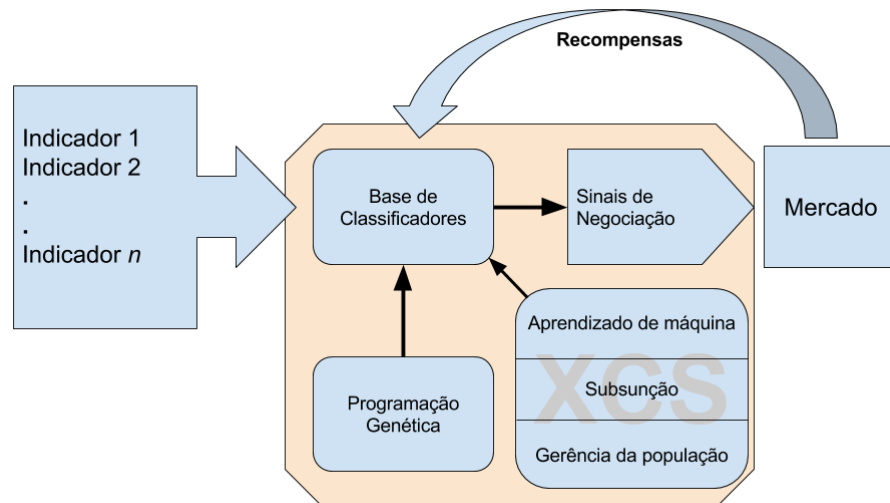


Figura 9 – Arquitetura do sistema desenvolvido

Fonte: (AUTORES, 2017)

A implementação do sistema foi realizada utilizando a linguagem de programação MQL5, uma linguagem desenvolvida especificamente para criar robôs de negociação para a plataforma *MetaTrader 5*<sup>3</sup>.

### 3.2.1 Indicadores

Representa a lista de indicadores considerados pelo sistema em sua tomada de decisão. Os indicadores técnicos são utilizados de duas formas: Para identificar sinais de

<sup>3</sup> <https://www.metatrader5.com/pt>

compra ou venda (na subárvore da esquerda), e para identificar tendências no valor do ativo (na subárvore da direita). Os indicadores escolhidos para este trabalho foram selecionados com base nos trabalhos relacionados e na preferência pessoal dos autores, buscando utilizar indicadores que representem os aspectos relevantes do ativo, como volume e valor de negociação. São utilizados os seguintes indicadores:

- *Chaikin Oscillator*: é um indicador formado pela junção dos volumes de negociação com 2 médias móveis, uma de 3 dias e outra de 10 dias. Este indicador é utilizado tanto para indicar tendência quanto para dar sinais de operação. Como indicador de tendência, uma tendência de alta (baixa) é representada pela linha de sinal acima (abaixo) do valor zero. Como indicador de operação, um sinal de compra (venda) é gerado quando a linha de sinal cruza o valor zero para cima (baixo);
- *Money Flow Index*: assim como o RSI, este indicador possui um valor entre 0 e 100 indicando a pressão compradora ou vendedora associada ao volume de negociação com base na média dos últimos 14 dias, e é utilizado tanto para indicar tendência quanto para dar sinais de operação. Como indicador de tendência, uma tendência de alta (baixa) é representada pela linha de sinal acima (abaixo) do valor 50, enquanto é considerado sem tendência se o valor estiver entre 40 e 60. Como indicador de operação, um sinal de compra (venda) é gerado quando a linha de sinal cruza o valor zero para cima (baixo). Além disso, outro sinal de operação possível através deste indicador é idêntico ao *retracement* do RSI (explicado na seção 2.3.3 do capítulo 2), quando a linha de sinal cruza a linha inferior (superior) para cima (baixo) sinalizando uma compra (venda);
- *Tripla Média Móvel*: este indicador é utilizado tanto para identificar tendências quanto para dar sinais de operação (através do cruzamento das médias rápida e média), conforme já foi descrito na seção 2.3.1 do capítulo 2. Para este trabalho foram utilizadas as médias de 5, 18 e 50 dias;
- *MACD*: este indicador é utilizado apenas para dar sinais de operação, conforme já foi descrito na seção 2.3.4 do capítulo 2. Para este trabalho foram utilizadas médias de 12 e 26 dias para a rápida e a lenta, enquanto que para a linha MACD foi utilizada a média de 9 dias;
- *RSI*: este indicador é utilizado tanto para indicar tendência quanto para dar sinais de operação. Como indicador de tendência, uma tendência de alta (baixa) é representada pela linha de sinal acima (abaixo) do valor 50, enquanto é considerado sem tendência se o valor estiver entre 40 e 60. Como indicador de operação, é utilizado o *retracement*, conforme

explicado na seção 2.3.3 do capítulo 2. Para este trabalho foi utilizada a média dos últimos 14 dias;

- *Parabolic SAR*: é um indicador que está sempre abaixo ou acima do preço atual, indicando uma tendência de alta ou de baixa. Explicado em maiores detalhes em Wilder (1978), este indicador recebe 2 parâmetros, sendo um fator de aceleração, que neste trabalho foi utilizado o valor 0.02 e um limite para o fator de aceleração, que neste caso foi adotado 0.2;
- *Rate of Change*: indica apenas a taxa de crescimento, em porcentagem do preço atual em relação a 12 dias atrás. Este indicador é utilizado como identificador de tendências caso o valor do crescimento (decréscimo) esteja acima (abaixo) de 5%, ou ausência de tendência caso a variação seja menor que 5%;
- *ADX*: este indicador infere a direção média do preço com base nos últimos 14 dias. Apesar de comumente utilizado tanto para identificar tendências quanto momentos de compra e venda, neste trabalho é utilizado como indicador de tendência apenas. Ele é composto por 3 linhas, onde as +DI e -DI indicam a tendência de subida e descida respectivamente, enquanto a linha ADX indica a força desta tendência. Neste trabalho, a linha ADX é utilizada para identificar se existe uma tendência, caso ela esteja acima do valor 20, e as linhas +DI e -DI utilizadas para identificar a direção da tendência (caso ela exista).

Todos os indicadores utilizados possuem um ou mais parâmetros. Estes parâmetros foram utilizados com seus valores *defaults* conforme a ferramenta *MetaTrader 5*.

### 3.2.2 Base de Classificadores

Representa as regras de negociação conhecidas pelo sistema. Possuem estrutura de árvore representando condições para que ocorra uma determinada ação. Sobre esta base de classificadores é que agem os módulos do XCS e a Programação Genética.

O nó raiz da árvore de decisão é formado por um operador “AND” que contém dois nós filhos que também são operadores “AND”. Em um dos nós filho é criada uma árvore de decisão contendo um ou mais nós com indicadores de tendência, enquanto no outro nó é criada uma árvore contendo indicadores que dão sinais de compra e venda, como pode ser observado na Figura 10. Esta restrição na estrutura da árvore garante que todos os sinais de operação são acompanhados de um sinal de tendência no mercado, reforçando assim o sinal dado. Na árvore, o valor depois do sinal de “igual” corresponde à saída daquele indicador, podendo ser “1” para compra, “-1” para venda” ou “0” para ausência de sinal ou sem tendência. Os números nos nós folha representam os parâmetros que cada indicador recebe

(normalmente o número de dias utilizados nas médias), com significado mudando para cada indicador.

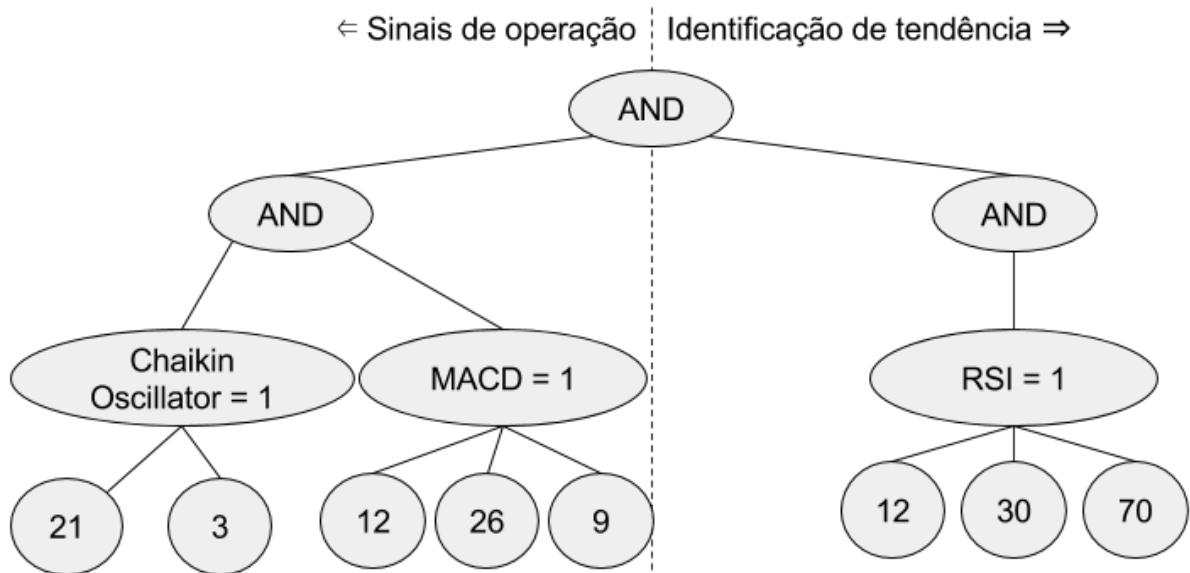


Figura 10 – Exemplo de árvore de decisão do classificador.

Fonte: (AUTORES, 2017)

Além da condição e da ação, cada classificador possui diversos atributos que são atualizados ao longo de sua vida. São eles:

- Recompensada esperada: toda vez que o classificador é selecionado para executar sua ação, a recompensada recebida é utilizada para atualizar esta variável, responsável por manter uma estimativa da recompensa média gerada por este classificador;
- Erro esperado: esta variável mantém uma estimativa dos erros nas predições;
- *Fitness*: atualizado pela Programação Genética, conforme a recompensa recebida;
- Experiência: número de vezes desde sua criação que este classificador participou de um Conjunto de Ação;
- Numerosidade: representa o número de indivíduos na população com condição/ação idêntica a este classificador. Assim, quando surgem novos indivíduos que são idênticos, ao invés de serem criados novos classificadores, é apenas incrementada a numerosidade de um deles.

### 3.2.3 Programação Genética

Este módulo é responsável por evoluir os classificadores para que se adequem ao ambiente existente no mercado. A escolha de utilizar árvore de decisão foi baseada no trabalho de Cirillo, Lloyd e Nordin (2014). A sua implementação é muito semelhante à implementação original da rotina “*RUN GA*”, descrita em Butz *et al.* (2001) e demonstrada na Figura 11, tendo como principais diferenças as rotinas “*APPLY Crossover*” e “*APPLY Mutation*”, descritas a seguir:

- *APPLY Crossover*: nesta rotina, ao invés de aplicar o *crossover* sobre um vetor de bits, neste trabalho ele é aplicado sobre uma árvore de decisão. Esta alteração é necessária, uma vez que está sendo utilizada uma árvore para a condição do classificador, ao invés de um vetor de *bits*. Inicialmente são escolhidos aleatoriamente 2 nós com indicadores na árvore de cada um dos filhos gerados. Depois, os dois filhos trocam entre si os nós que estiverem entre os 2 selecionados;
- *APPLY Mutation*: esta rotina exclui um nó aleatoriamente da árvore, ou acrescenta um nó representando um indicador que não existia antes neste classificador.

A rotina “*RUN GA*” verifica a cada ciclo se o Conjunto de Ação (descrito na seção seguinte) possui experiência suficiente para participar do processo evolutivo, e caso não o seja, não evolui os classificadores neste ciclo. Depois, são selecionados no conjunto dois classificadores para serem pais, através do algoritmo de roleta utilizando o *fitness* como base para o sorteio. A partir dos dois pais selecionados, são criados dois classificadores filho idênticos aos pais, mas com alguns atributos reinicializados (numerosidade e experiência) e possivelmente aplicando as operações de *crossover* e mutação descritas anteriormente. Caso um ou ambos os filhos possuam uma condição que já seja representada por outro classificador, eles podem ser subsumidos. Ao final é aplicado o controle de população caso o limite de indivíduos tenha sido ultrapassado, removendo os indivíduos com menores *fitness* através do algoritmo de roleta também.

```

RUN GA([A],  $\sigma$ , [P]):
1 if(actual time  $t - \sum_{cl \in [A]} ts_{cl} * num_{cl} / \sum_{cl \in [A]} num_{cl} > \theta_{GA}$ )
2   for each classifier  $cl$  in [A]
3      $ts_{cl} \leftarrow$  actual time  $t$ 
4    $parent_1 \leftarrow$  SELECT OFFSPRING in [A]
5    $parent_2 \leftarrow$  SELECT OFFSPRING in [A]
6    $child_1 \leftarrow$  copy classifier  $parent_1$ 
7    $child_2 \leftarrow$  copy classifier  $parent_2$ 
8    $num_{child_1} = num_{child_2} \leftarrow 1$ 
9    $exp_{child_1} = exp_{child_2} \leftarrow 0$ 
10  if(RandomNumber[0,1) <  $\chi$ )
11    APPLY CROSSOVER on  $child_1$  and  $child_2$ 
12     $p_{child_1} \leftarrow (p_{parent_1} + p_{parent_2}) / 2$ 
13     $\epsilon_{child_1} \leftarrow (\epsilon_{parent_1} + \epsilon_{parent_2}) / 2$ 
14     $f_{child_1} \leftarrow (f_{parent_1} + f_{parent_2}) / 2$ 
15     $p_{child_2} \leftarrow p_{child_1}$ 
16     $\epsilon_{child_2} \leftarrow \epsilon_{child_1}$ 
17     $f_{child_2} \leftarrow f_{child_1}$ 
18     $f_{child_1} \leftarrow f_{child_1} * 0.1$ 
19     $f_{child_2} \leftarrow f_{child_2} * 0.1$ 
20  for both children  $child$ 
21    APPLY MUTATION on  $child$  according to  $\sigma$ 
22    if(doGASubsumption)
23      if(DOES SUBSUME  $parent_1, child$ )
24         $num_{parent_1}++$ 
25      else if(DOES SUBSUME  $parent_2, child$ )
26         $num_{parent_2}++$ 
27      else
28        INSERT  $child$  IN POPULATION
29    else
30      INSERT  $child$  IN POPULATION
31    DELETE FROM POPULATION [P]

```

Figura 11 – Rotina “*RUN GA*”.

Fonte: (BUTZ *et al.*, 2001)

### 3.2.4 XCS

Este módulo é a peça central do sistema negociador, responsável pelo aprendizado do sistema. A cada ciclo, a situação do ambiente (neste caso, os valores de compra e venda do ativo no mercado e os valores dos indicadores) é recebida como entrada. A partir disso, a base de classificadores é percorrida e são selecionados todos os classificadores com condições (árvores de decisão) correspondentes à entrada recebida, formando o “Conjunto de Correspondência”. Caso nenhum classificador corresponda à situação do ambiente, são criados novos classificadores com condições adequadas ao ambiente e ação aleatória. Depois, a partir dos classificadores no Conjunto de Correspondência, é criado o Vetor de Predição, que prediz para cada ação possível, a recompensa esperada.



A partir das recompensas esperadas, é selecionada uma ação e é formado o “Conjunto de Ação”, contendo todos os classificadores do Conjunto de Correspondências que possuam a ação selecionada. Depois disso, a ação é executada no mercado (é realizada uma operação de compra ou venda, ou mantida a posição atual). Depois, os classificadores do Conjunto de Ação recebem a recompensa de acordo com o movimento que o preço do ativo tomou de fato, após a operação. Neste momento, é aplicada a Programação Genética para evoluir os classificadores que tiverem um mínimo de experiência necessária para participar deste processo. A qualquer momento que surjam novos classificadores, através da Programação Genética, por exemplo, é verificado através de um mecanismo de Subsunção, se a condição deste novo classificador já não está contida em outro classificador mais genérico e experiente. Se for o caso de já existir um classificador mais genérico, então o novo classificador não é inserido na população, e o antigo tem sua numerosidade incrementada.

#### 3.2.4.1 Aprendizado de máquina

No tratamento das recompensas, o XCS utiliza uma abordagem semelhante ao Q-Learning, descrito em Sutton e Barto (2012), com a diferença que, ao invés de utilizar a recompensa para atualizar um par estado-ação, no XCS ela é utilizada para atualizar regras genéricas representadas pela condição dos classificadores. A cada ciclo, a recompensa recebida pelos classificadores é utilizada para atualizar a estimativa de recompensas futuras e a estimativa de erro destes, conforme a Equação 1, onde  $\beta$  é a taxa de aprendizado, estabelecida em 0,1. A partir destas estimativas atualizadas, o *fitness* do classificador é atualizado.

$$estAtual = estAnterior + \beta * (recompensa - estAnterior)$$

(Equação 1)

Fonte: Butz *et al.* (2001)

#### 3.2.4.2 Subsunção

A qualquer momento que surjam novos classificadores, através da Programação Genética, por exemplo, é verificado através de um mecanismo de Subsunção, se a condição deste novo classificador já não está contida em outro classificador mais genérico e experiente.

Se for o caso de já existir um classificador mais genérico, então o novo classificador não é inserido na população, e o antigo tem sua numerosidade incrementada.

Este procedimento é realizado percorrendo as árvores do classificador mais novo e comparando com a árvore de todos os classificadores existentes na população com experiência suficiente. Se os indicadores presentes na árvore do novo classificador forem idênticos ou não existirem na árvore do classificador mais experiente, este novo indicador pode ser subsumido pelo mais experiente.

### 3.2.4.3 Gerência de população

A gerência da população é responsável por inserir novos indivíduos na população quando não houver classificador cuja condição corresponda ao ambiente atual, e também é responsável por removê-los quando houver mais indivíduos que o limite de população estabelecido (1000 indivíduos). Foi escolhido este limite de população por se tratar do menor valor que não afeta negativamente o desempenho da estratégia com base nos testes realizados. Valores maiores foram testados, mas não foram observadas melhorias.

A inserção de novos classificadores (quando não for através da reprodução de indivíduos na Programação Genética) ocorre na etapa de formação do Conjunto de Correspondência, no caso de não haver classificador que corresponda à situação no ambiente. Neste caso, um novo classificador com ação aleatória é criado de forma que a árvore em sua condição possua apenas nodos correspondentes à situação atual no ambiente.

Para a exclusão de indivíduos da população, é utilizado um algoritmo de roleta, dando maior chance para os classificadores com menor *fitness* na população. Esta rotina é executada toda vez que um indivíduo novo é inserido na população.

### 3.2.5 Sinais de Negociação

São as ações determinadas pela base de classificadores. Os sinais possíveis são “Compra”, “Manter posição atual” e “Venda”. Quando o sistema toma a decisão de realizar a compra de um ativo, por exemplo, é enviado um sinal para os servidores da corretora utilizando a plataforma *MetaTrader 5*. Os servidores respondem indicando se a operação foi um sucesso (compra executada), ou se houve falha, como, por exemplo, erro na comunicação ou volume ofertado inferior ao requisitado pelo cliente, entre outros. A corretora disponibiliza

servidores para realizar operações tanto em contas “demo”, utilizadas como treinamento sem movimentações reais, quanto em contas reais, utilizando dinheiro real.

### 3.2.6 Recompensas

É o *feedback* que o XCS recebe sobre as decisões tomadas. Caso o sistema mande comprar determinado ativo e o valor deste ativo sobe em um futuro próximo, o XCS dá uma recompensa positiva para os classificadores que fizeram parte da decisão de compra, atualizando suas previsões de recompensa e de erro, e consequentemente aumentando o *fitness* destes. Esta recompensa é calculada 3 dias após a execução da ação. O período de 3 dias foi adotado arbitrariamente por não impactar de forma significativa nos resultados, com base nos testes realizados. O valor desta recompensa é a diferença entre o preço do ativo na operação executada e o preço do ativo no momento que está sendo calculada a recompensa, podendo assumir valores negativos em caso de prejuízo.

## 3.3 Carregamento do sistema negociador na plataforma *MetaTrader 5*

Na plataforma *MetaTrader 5*, um sistema negociador, ou robô de negociação é chamado de *Expert Advisor* (EA). A criação de um EA é realizada através do *MetaEditor*, uma IDE integrada ao *MetaTrader 5*. O *MetaEditor* possui um compilador da linguagem MQL5 que cria executáveis \*.ex5 a partir dos códigos-fonte \*.mq5 e \*.mqh. Quando o desenvolvedor compila o seu *Expert Advisor*, conforme a Figura 12, o executável é carregado no *MetaTrader 5*.

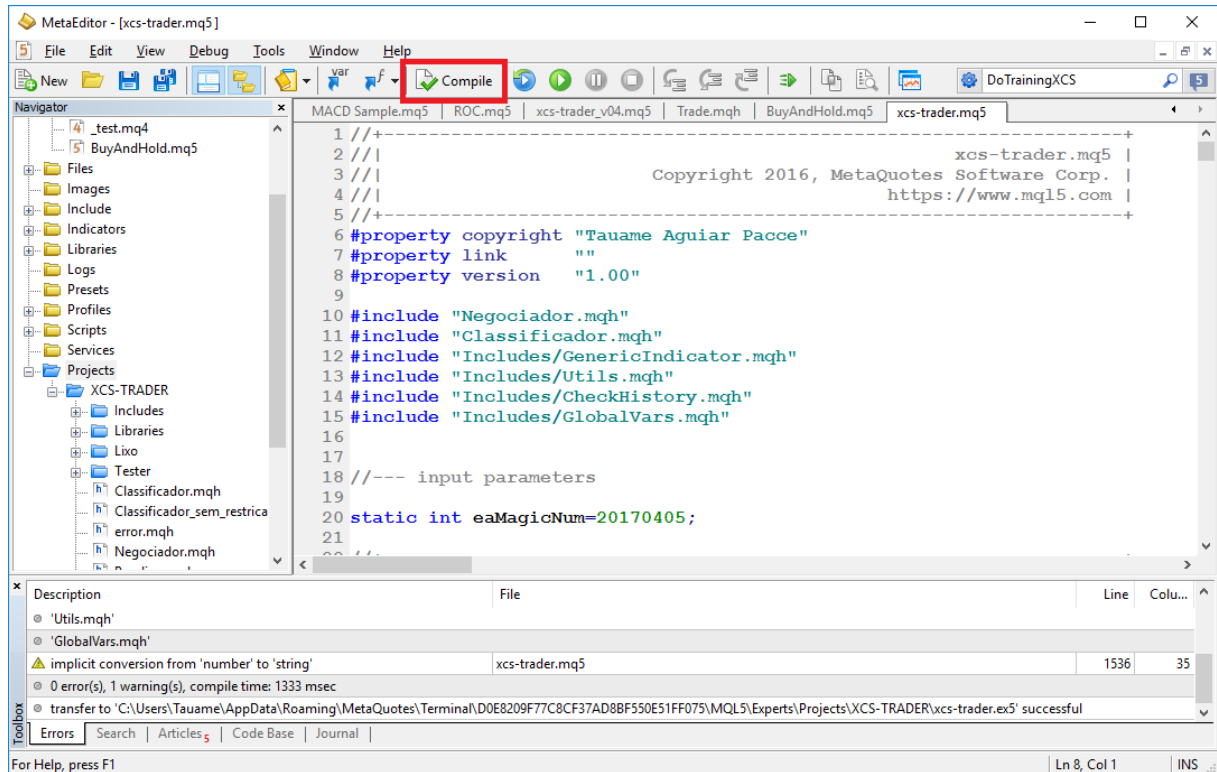


Figura 12 – Compilação do código-fonte no *MetaEditor*.

Fonte: (AUTORES, 2017)

O módulo da plataforma responsável pela realização de testes com dados históricos é o *Strategy Tester*, que permite a realização de testes com diferentes configurações, como por exemplo: ativo a ser negociado, data inicial e final dos dados utilizados, duração da barra (podendo utilizar desde barras de 1 minuto até barras mensais), saldo inicial, alavancagem (recurso comum no mercado FOREX para multiplicar os resultados, sejam positivos ou negativos), simulação de atraso na operação, e otimização de parâmetros de entrada. Este módulo pode ser observado na parte inferior da Figura 13.

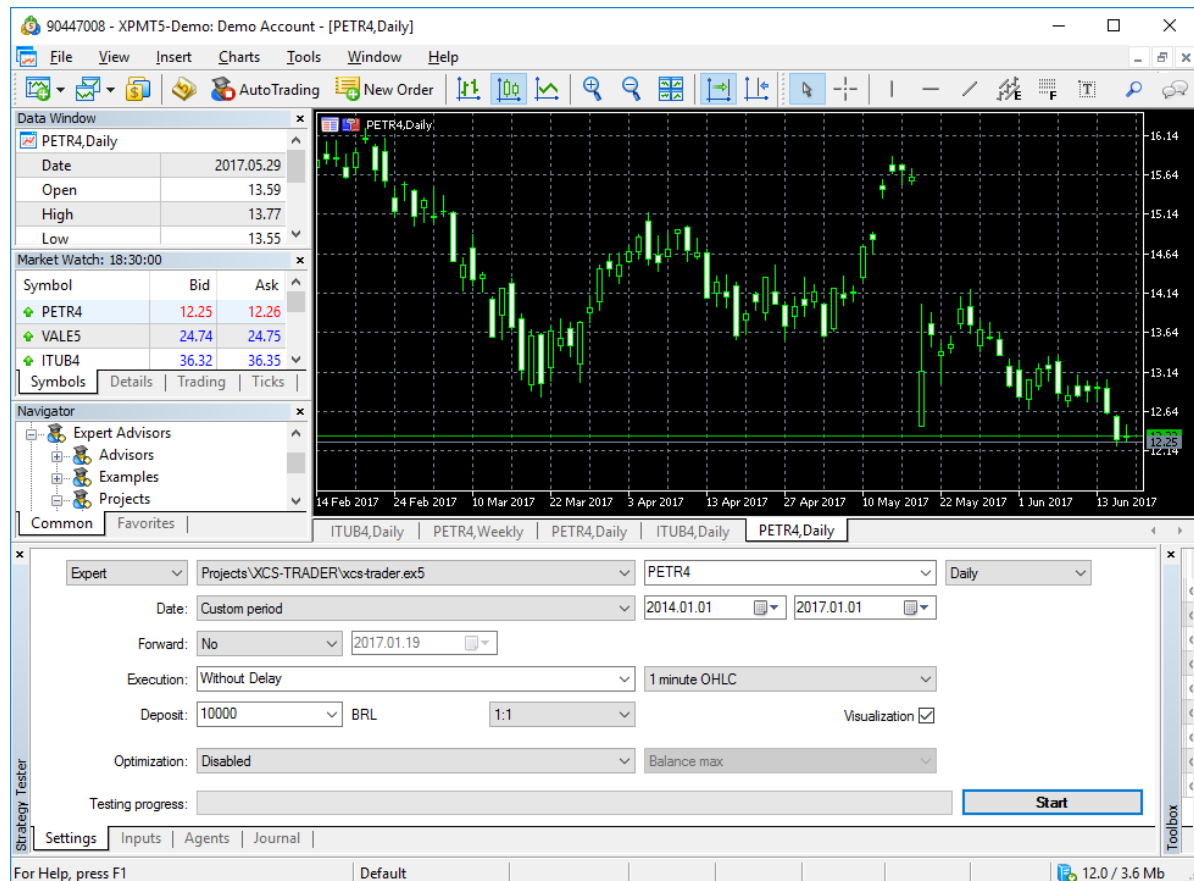


Figura 13 – *Strategy Tester* dentro da plataforma *MetaTrader 5*.

Fonte: (AUTORES, 2017)

Quando um EA é testado, uma visualização separada do *Strategy Tester* permite acompanhar a simulação, conforme o tempo passa para o EA e ele emite sinais de compra e de venda do ativo. Do ponto de vista do EA, é como se ele estivesse realmente sendo executado no passado e suas operações estivessem sendo executadas de fato pela corretora, inclusive alterado o saldo fictício da conta. Na Figura 14, pode-se observar as operações que o EA está executando (setas vermelhas e azuis sobre os *candles*), assim como o valor de todos os indicadores utilizados.

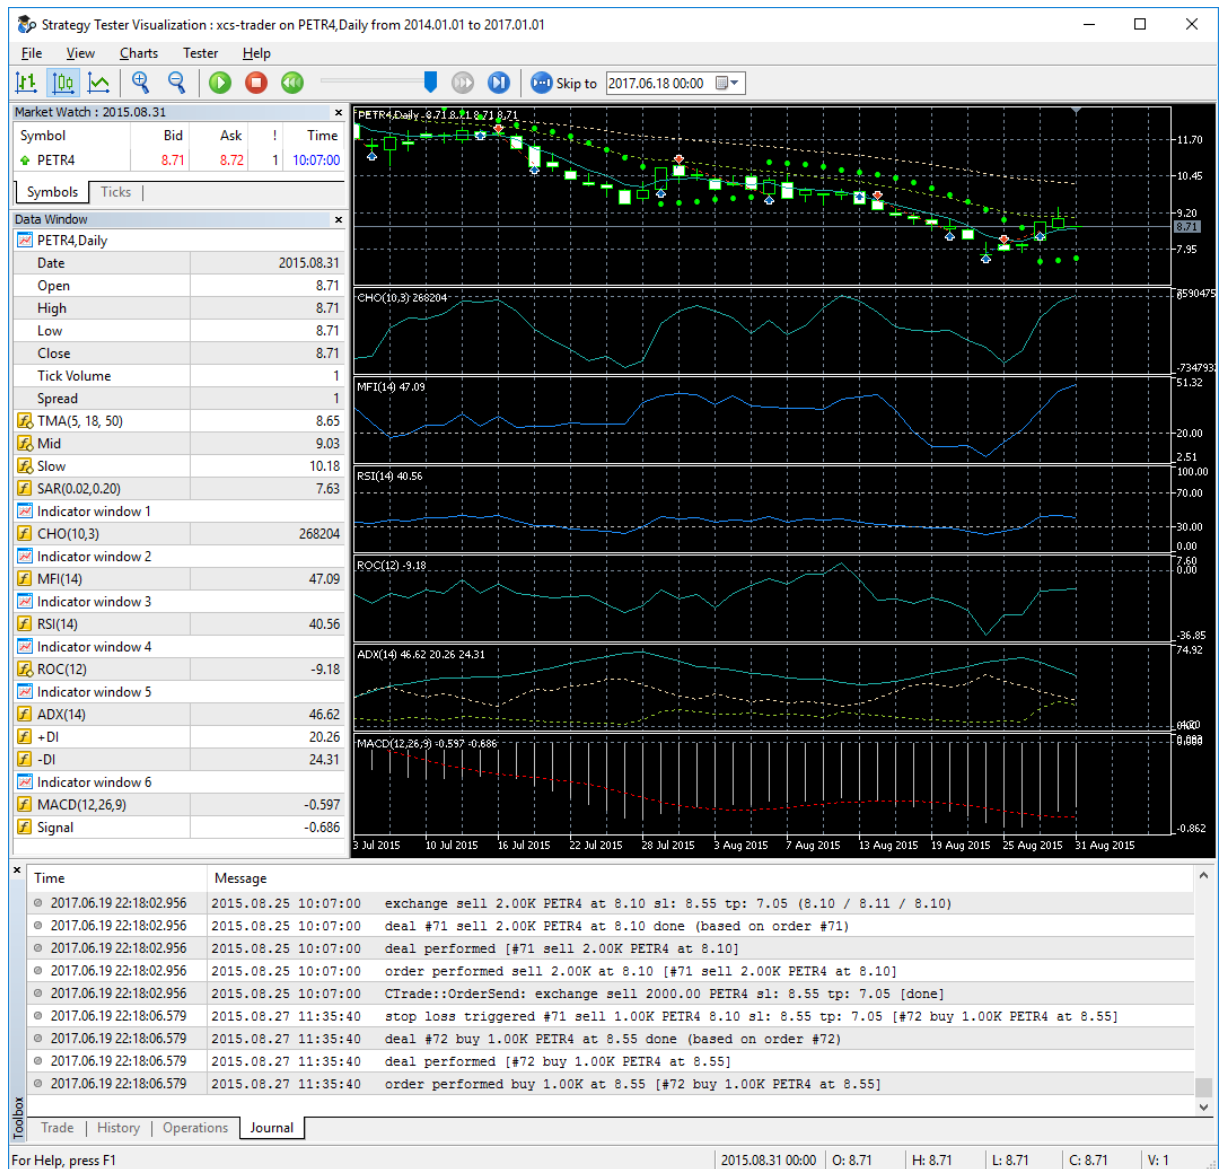


Figura 14 – Visualização da simulação no *Strategy Tester*.

Fonte: (AUTORES, 2017)

## 4 RESULTADOS E DISCUSSÕES

Neste capítulo, é descrita a abordagem utilizada para avaliar o trabalho desenvolvido, demonstrando os testes realizados, com seus respectivos resultados, e por fim estes resultados são avaliados e comparados aos dos trabalhos relacionados.

### 4.1 Metodologia de Avaliação

Para avaliar o sistema desenvolvido, foi utilizado o módulo “*Strategy Tester*” da plataforma *MetaTrader 5* utilizando dados históricos fornecidos pelos servidores de negociação da corretora XP Investimentos.

Foram realizadas 10 simulações, com o sistema operando sobre *candles*<sup>4</sup> diários do ativo PETR4 entre 01/01/2014 e 01/01/2017. Foi selecionado o ativo PETR4 por se tratar de um papel com alta liquidez. Cada simulação inicia com R\$10.000,00 na conta e mantém posições abertas de 10 lotes de 100 ações, totalizando 1000 ações. Não foi utilizado mecanismo de gerência de dinheiro ou risco, com exceção da configuração de *Stop Loss* de 50 pontos (R\$0,50 por ação) e *Take Profit* de 100 pontos (R\$1,00 por ação) em todas as operações.

O *Stop Loss* é uma forma de limitar o prejuízo causado por uma negociação desfavorável. Quando o valor do ativo cai o suficiente para passar o limite definido no *Stop Loss*, a posição comprada é fechada imediatamente pelo valor do ativo atual do mercado, impedindo assim que o prejuízo seja maior caso o valor continuasse se movendo em direção desfavorável. Um *Stop Loss* de 50 pontos no contexto do ativo PETR4 significa que se o preço do ativo cair R\$0,50 após a compra é realizada uma venda automática para fechar a posição e limitar as perdas.

Um conceito semelhante ao *Stop Loss* é o *Take Profit*, que serve para garantir o lucro obtido até o momento. No momento da compra do ativo, pode ser definido um valor de *Take Profit*. Assim, se o preço do ativo subir o suficiente para alcançar o valor definido, é realizada uma venda automaticamente, para efetivar o lucro. Um *Take Profit* de 100 pontos no contexto

---

<sup>4</sup> Barras representando o valor inicial, final, máximo e mínimo do preço de negociação de um ativo em determinado período (1 minuto, 5 minutos, 1 dia, 1 semana, outros períodos).

do ativo PETR4 significa que se o preço subir R\$1,00 após a compra é realizada uma venda automática para fechar a posição e garantir o lucro obtido até o momento.




Figura 15 – Janela deslizando.

Fonte: (AUTORES, 2017)

Durante a simulação, é utilizada uma janela deslizando, que pode ser visualizada na Figura 15, de forma que em cada dia da simulação (ou para cada *candle* novo) o sistema avalia os últimos 500 *candles* (aproximadamente 2 anos de dados), executando o XCS 400 vezes sobre estes 500 *candles*, totalizando 200.000 ciclos do XCS. A população de classificadores evoluídos no dia anterior é sempre aproveitada como população inicial no dia seguinte.

O *Strategy Tester* disponibiliza uma margem para realizar as negociações, de maneira que é possível comprar 1000 ações a R\$15,00 (uma operação de R\$15.000,00) mesmo com um saldo inicial de R\$10.000,00. Esta prática é comum nas corretoras, sendo disponível também na XP Investimentos.

Ao final de cada simulação, a plataforma gera um relatório detalhado das operações executadas, incluindo estatísticas que são utilizadas na seção seguinte para avaliar o desempenho do sistema. Um exemplo de relatório pode ser observado na Figura 16.



Results			
History Quality:	94%		
Bars:	991	Ticks:	1627862
Total Net Profit:	8 260.00	Balance Drawdown Absolute:	420.00
Gross Profit:	49 520.00	Balance Drawdown Maximal:	4 810.00 (30.81%)
Gross Loss:	-41 260.00	Balance Drawdown Relative:	30.81% (4 810.00)
		Equity Drawdown Absolute:	720.00
		Equity Drawdown Maximal:	5 350.00 (33.73%)
		Equity Drawdown Relative:	33.73% (5 350.00)
Profit Factor:	1.20	Expected Payoff:	40.89
Recovery Factor:	1.54	Sharpe Ratio:	0.10
AHPR:	1.0037 (0.37%)	LR Correlation:	0.89
GHPR:	1.0030 (0.30%)	LR Standard Error:	1 660.77
		Margin Level:	226.94%
		Z-Score:	0.31 (24.34%)
		OnTester result:	0
Total Trades:	202	Short Trades (won %):	101 (42.57%)
Total Deals:	307	Profit Trades (% of total):	88 (43.56%)
		Long Trades (won %):	101 (44.55%)
		Loss Trades (% of total):	114 (56.44%)
		Largest profit trade:	1 050.00
		Average profit trade:	562.73
		Largest loss trade:	-450.00
		Average loss trade:	-361.93
		Maximum consecutive wins (\$):	5 (4 840.00)
		Maximum consecutive losses (\$):	6 (-2 700.00)
		Maximal consecutive profit (count):	4 840.00 (5)
		Maximal consecutive loss (count):	-2 700.00 (6)
		Average consecutive wins:	2
		Average consecutive losses:	2




Figura 16 – Relatório da simulação gerado pelo *MetaTrader 5*.

Fonte: (AUTORES, 2017)

Para realizar os testes, foi utilizado um computador com processador AMD FX-8350 4.00 GHz, 16 GB de memória, SSD de 240GB com sistema operacional *Windows 10*.

## 4.2 Resultados

A partir dos resultados obtidos após 10 simulações executadas, foi construída a Tabela 2. As 10 simulações foram executadas com as mesmas condições e mesmos parâmetros. Estes resultados não consideram custos de operação ou taxas de corretagem. O cálculo do lucro médio leva em consideração apenas negociações vencedoras, assim como a perda média considera apenas as perdedoras.

Tabela 2 – Resultados obtidos das 10 simulações.

Sim.	Número de Negociações com Lucro	Número de Negociações com Perda	Lucro Médio (R\$)	Perda Média (R\$)	Draw down Máx.	Número de Neg.	Lucro/Perda Líquido Total (R\$)
1	79 (39,11%)	123 (60,89%)	519,24	345,37	53,52%	202	-1.460,00
2	76 (42,94%)	101 (57,06%)	550,79	360,40	29,14%	177	5.460,00
3	78 (46,43%)	90 (53,57%)	576,79	389,67	33,20%	168	9.920,00
4	88 (43,56%)	114 (56,44%)	562,73	361,93	30,81%	202	8.260,00
5	55 (39,01%)	86 (60,99%)	524,18	350,93	59,58%	141	-1.350,00
6	78 (39,00%)	122 (61,00%)	561,15	352,30	57,05%	200	790,00
7	72 (36,55%)	125 (63,45%)	598,06	364,24	55,12%	197	-2.470,00
8	89 (51,74%)	83 (48,26%)	553,82	369,88	13,89%	172	18.590,00
9	99 (47,60%)	109 (52,40%)	528,69	369,82	28,30%	208	12.030,00
10	64 (42,67 %)	86 (57,33%)	622,50	396,40	35,94%	150	5.750,00

Fonte: (AUTORES, 2017)

(Legenda: Sim – Simulação; Máx – Máximo; Neg – Negociação)

Com exceção da simulação 8, em todas as simulações a estratégia realizou mais negociações com perdas do que lucros, isso é um reflexo da utilização de um *Stop Loss* menor que o *Take Profit*, fazendo com que a variação do preço frequentemente atinja a linha de *Stop Loss*, resultando em negociações perdedoras, mas de baixo valor. Por este mesmo motivo, em todas as simulações o lucro médio foi maior que a perda média, uma vez que o *Stop Loss* limita a quantidade de dinheiro perdida durante cada operação realizada.

O *Drawdown* elevado em quase todas as simulações (média de 39,55%) se deve à ausência de gerência de risco na estratégia adotada, fazendo com que, por vezes, o saldo tenha quedas significativas antes de uma nova alta, ou vice-versa.

A flutuação do saldo na conta ao longo do tempo para cada uma das 10 simulações pode ser observada na Figura 17, e para fins de comparação, a estratégia de *Buy-and-Hold* pode ser visualizada na Figura 18. O *Buy-and-Hold* é uma estratégia de longo prazo que consiste em realizar apenas uma compra do ativo e mantê-lo em sua carteira por um grande período, realizando a venda apenas quando se deseja concluir o investimento. Assim, nesta estratégia, a variação do valor do ativo é diretamente proporcional à variação do saldo na conta. Pode-se observar que apesar da grande diferença de resultados, em determinados

momentos todas as simulações apresentam comportamentos semelhantes. Isto pode ser observado no período entre julho e setembro de 2015, onde todas as simulações realizaram lucros, enquanto a estratégia de *Buy-and-Hold* apresentou perdas consistentes no mesmo período.




Figura 17 – Saldo da conta durante as simulações.

Fonte: (AUTORES, 2017)



Figura 18 – Saldo da conta utilizando a estratégia *Buy-and-Hold*.

Fonte: (AUTORES, 2017)

A grande variação nos resultados pode ser atribuída à aleatoriedade inerente de algoritmos evolutivos, associada ao ambiente incerto do mercado financeiro. Múltiplos classificadores diferentes podem obter altos valores de *fitness* para a mesma situação, fazendo com que múltiplas execuções do algoritmo cheguem a resultados diferentes, dependendo de quão generalistas são as regras evoluídas no sistema.

### 4.3 Discussões

Nesta seção, os resultados deste trabalho são comparados com os dos trabalhos relacionados, levando em consideração um caráter preferencialmente qualitativo, uma vez que os trabalhos foram aplicados sobre mercados diferentes com abordagens de avaliação diferentes.

O trabalho de Hu *et al.* (2015a) apresentou resultados consistentes ao longo de 12 anos, atingindo 10% de lucro por ano aliado a um alto índice de Sortino. O índice de Sortino é uma métrica de avaliação de risco que associa o retorno financeiro ao risco decorrente de movimentos desfavoráveis no valor do ativo negociado (HU *et al.*, 2015a). Apesar deste trabalho não ter sido avaliado sobre o índice de Sortino, imagina-se que seriam obtidos valores próximos de 0 na maioria das simulações, dados os elevados níveis de *drawdown* máximo causado pela ausência de gerência de risco. Além disso, o lucro médio sobre as 10

simulações de 55,52% (cerca de 15,86% ao ano) obtido neste trabalho ao longo de 3 anos não pode ser comparado aos resultados de Hu *et al.* (2015a), devido ao curto período de avaliação, uma vez que o outro trabalho foi testado sobre 12 anos.

Em Dash e Dash (2016), apesar dos resultados surpreendentes, obtendo 24,28% de lucro em um índice e 47,2% em outro ao longo de apenas um ano, o trabalho não apresenta testes sobre períodos maiores. Caso este trabalho tivesse sido avaliado apenas sobre o ano de 2015, por exemplo, ele provavelmente apresentaria resultados ótimos, uma vez que neste ano houve períodos em que todas as simulações foram lucrativas. Por este motivo optou-se por avaliar o trabalho sobre 3 anos dados.

Em relação ao trabalho de Cirillo, Lloyd e Nordin (2014), o sistema desenvolvido apresenta resultados comparáveis aos melhores indivíduos evoluídos, mas apenas quando estes são aplicados sobre o conjunto de dados de avaliação, onde obtiveram o pior desempenho. Os autores preferiram uma abordagem utilizando populações grandes com poucos ciclos de evolução, ao contrário deste trabalho, onde foram aplicados milhares de ciclos sobre os indivíduos de uma população menor.

No trabalho de Chiang *et al.* (2016), em compensação à utilização de apenas 1 ano de avaliação, foram utilizados diversos ativos, sendo que em todos eles os resultados foram positivos e consistentes. Um aspecto relevante é o baixo número de transações, sendo executadas entre 10 e 20 transações no ano de teste, em comparação ao número entre 141 e 202 transações (em 3 anos) deste trabalho. A abordagem por *wavelets* para redução de ruído poderia ser utilizada para tentar minimizar o número de transações no sistema desenvolvido.

## 5 CONCLUSÃO

O trabalho desenvolvido contribuiu para o desenvolvimento do uso de técnicas de inteligência artificial aplicadas à área de tomada de decisão no mercado financeiro, de maneira a reduzir os riscos inerentes da operação de ativos de renda variável, disponibilizando uma fonte extra de informação para auxiliar os investidores durante uma tomada de decisão.

Assim, foi apresentada uma estratégia de negociação baseada em *eXtended Classifier Systems* e Programação Genética para atuação em mercados de capitais, através da utilização de indicadores técnicos.

Após as análises feitas na seção de validação, concluiu-se que os resultados atingidos são compatíveis com outros trabalhos na área. Apesar do alto número de operações perdedoras, causado pelo *Stop Loss* muito próximo ao preço de negociação, a estratégia obteve lucro na maioria das simulações executadas, pois as operações vencedoras obtiveram lucro superior (R\$193,70 por operação em média) ao prejuízo médio das operações perdedoras. No entanto, a estratégia pode ser melhorada, pois observou-se uma grande variação nos resultados e um *drawdown* elevado em quase todas as simulações (média de 39,55%), indicando a necessidade de uma gerência de risco na estratégia desenvolvida.

Como resposta ao problema de pesquisa “Como uma estratégia de negociação, baseada em técnicas de Inteligência Artificial, que utiliza indicadores, pode auxiliar na decisão em relação às operações de compra e venda de ativos no mercado de capitais?”, o trabalho demonstra que a utilização de *eXtended Classifier Systems* aliada à Programação Genética pode utilizar indicadores técnicos para auxiliar a tomada de decisão no mercado de capitais.

No Quadro 1, apresentado na seção 2.5.5 do capítulo 2, há uma comparação entre os trabalhos relacionados estudados. Retomando-se o quadro, inclui-se aqui as características do sistema desenvolvido.

Trabalhos Relacionados	Objetivo	Tipo de Análise	Técnicas de negociação utilizadas	Dados utilizados	Resultados
(PACCE e FROZZA, 2017)	Desenvolver uma estratégia de negociação, baseada em XCS e Programação Genética, utilizando indicadores técnicos que possibilitem a decisão em relação à compra ou venda de ativos em mercado de capitais.	Análise Técnica	XCS aliado à Programação Genética com 8 indicadores técnicos utilizados para identificação de tendências e pontos de entrada e saída.	Barras diárias do Ativo PETR4 da BM&F Bovespa entre janeiro de 2014 e janeiro de 2017, com janela deslizante de 2 anos anteriores.	Retorno médio sobre 3 anos de 55%, mas com alto número de operações e <i>drawdown</i> máximo elevado.

Como trabalhos futuros, sugere-se:

- Incluir na evolução da Programação Genética os parâmetros dos indicadores, para que o sistema possa otimizar não só o melhor conjunto de classificadores para cada situação, mas também a parametrização destes indicadores técnicos.
- Aplicar a remoção de ruído através de *wavelets* sobre os preços dos ativos para tentar contrapor a variação inerente existente no mercado financeiro, buscando reduzir o número de operações executadas, e consequentemente os custos de operação.
- Testar a utilização de uma população maior de indivíduos com maior grau de exploração e menos ciclos de evolução, a fim de buscar regras de negociação mais genéricas e que possam ser aplicadas em diversas situações.
- Incluir módulos de gerência de risco e gerência de capital, para que o sistema possa determinar a quantidade de dinheiro a ser investido em cada operação e tentar minimizar o *drawdown* máximo. Outras estratégias de gerência de risco também podem ser aplicadas, como compras e vendas parciais, ou utilização de *trailing stops*.

- Utilizar *data mining* para identificar os sinais mais significativos para um determinado ativo e, a partir destes sinais, aplicar este trabalho.



## REFERÊNCIAS

- ACHELIS, S. *Technical Analysis from A to Z*. 2ª ed. McGraw-Hill Professional. 2000.
- BLUME, L.; EASLEY, D.; O'HARA, M. *Market Statistics and Technical Analysis: The Role of Volume*. In: The Journal of Finance. Vol 49. Nº 1. p. 153-181. JSTOR. 1994. Disponível em <<http://technicalanalysis.org.uk/volume/BIEO94.pdf>>, acessado em 27 de setembro de 2016.
- BM&F BOVESPA. *Introdução ao Mercado de Capitais*. 2010. Disponível em: <[https://corretora.miraeasset.com.br/global/bz/po/downloads/cursosOnline/Introdu%C3%A7%C3%A3o\\_ao\\_Mercado\\_de\\_Capitais.pdf](https://corretora.miraeasset.com.br/global/bz/po/downloads/cursosOnline/Introdu%C3%A7%C3%A3o_ao_Mercado_de_Capitais.pdf)>, acessado em 12 de agosto de 2016.
- BOOTH, A.; GERDING, E.; MCGROARTY, F. *Automated trading with Performance Weighted Random Forests and Seasonality*. In: Expert Systems with Application. Vol 41. Issue 8. p. 3651-3661. 2014. Disponível em: <<https://www.researchgate.net/publication/259991877>>, acessado em 07 de agosto de 2016.
- BROCK, W.; LAKONISHOK, J.; LeBARON, B.; *Simple Technical Trading Rules and the Stochastic Properties of Stock Returns*. In: The Journal of Finance. Vol. 47. Issue 5. p. 1731-1764. 1992. Disponível em <<https://cdn.preterhuman.net/texts/unsorted2/Stock%20books%20045/Simple%20Technical%20Trading%20Rules%20And%20The%20Stochastic%20Properties.pdf>>, acessado em 22 de outubro de 2016.
- BULL, L. *Learning Classifier Systems: A Brief Introduction*. In: Studies of Fuzziness and Soft Computing: Applications of Learning Classifier Systems. Vol 150. p. 1-12. Springer Berlin Heidelberg. 2004. Disponível em: <<http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.107.9784&rep=rep1&type=pdf>>, acessado em 3 de novembro de 2016.
- BUTZ, M. V.; KOVACS, T.; LANZI, P. L.; WILSON, S. W. *How XCS Evolves Accurate Classifiers*. In: Proceeding of the 3<sup>rd</sup> Annual Conference on Genetic and Evolutionary Computation. p. 927-934. Morgan Kaufmann Publishers Inc. San Francisco, CA. United States of America. 2001. Disponível em: <<http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.16.2183&rep=rep1&type=pdf>>, acessado em 3 de novembro de 2016.
- CHAVES, Daniel Augusto Tucci, *Análise técnica e fundamentalista: divergências, similaridades e complementariedades*. Universidade de São Paulo. São Paulo, 2004.
- CHIANG, W.; ENKE, D.; WE, T.; WANG R. *An adaptive stock index trading decision support system*. In: Expert Systems With Applications. Vol. 59. p. 195-207. 2016. Disponível em <[https://www.researchgate.net/profile/David\\_Enke/publication/301831445\\_An\\_adaptive\\_stock\\_index\\_trading\\_decision\\_support\\_system/links/573088a708aee022975c44cd.pdf](https://www.researchgate.net/profile/David_Enke/publication/301831445_An_adaptive_stock_index_trading_decision_support_system/links/573088a708aee022975c44cd.pdf)>, acessado em 28 de outubro de 2016.
- CIRILLO, S.; LLOYD, S.; NORDIN, P. *Evolving intraday foreign exchange trading strategies utilizing multiple instruments price series*. In: Computer Research Repository. 2014. Disponível em: <<http://arxiv.org/abs/1411.2153>>, acessado em 30 de outubro de 2016.
- CURCIO, R.; GOODHART, C. A. E. *When Support/Resistance Levels are Broken, Can Profits be Made? Evidence from the Exchange Market*. In: LSE Financial Markets Group Discussion Paper

Series. 1992. Disponível em: <<http://www.lse.ac.uk/fmg/workingPapers/discussionPapers/fmgdps/DP142.pdf>>, acessado em 26 de outubro de 2016.

DASH, R.; DASH, P. K. *A hybrid stock trading framework integrating technical analysis with machine learning techniques*. In: The Journal of Finance and Data Science. Vol. 2. Issue 1. p. 42-57. 2016. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S2405918815300179>>, acessado em 30 de outubro de 2016.

FU, T. -c.; CHUNG, C. -p.; CHUNG, F. -l. *Adopting genetic algorithms for technical analysis and portfolio management*. In: Computers and Mathematics with Applications. Vol. 66, Issue 10. p. 1743-1757. 2013.

GIACOMEL, F. dos S. *Um método Algorítmico para Operações na Bolsa de Valores Baseado em Ensembles de Redes Neurais para Modelar e Prever os Movimentos dos Mercados de Ações*. Dissertação de Mestrado para o Programa de Pós-Graduação em Computação da Universidade Federal do Rio Grande Do Sul. Porto Alegre. 2016. Disponível em <<http://www.lume.ufrgs.br/bitstream/handle/10183/134586/000988403.pdf>>, acessado em 11 de agosto de 2016.

GOODMAN, T.; NEAMTIU, M.; ZHANG, X. F. *Funtamental Analysis and Option Returns*. In: Financial Accounting & Reporting Sections 2012 (FARS 2012). 2012. Disponível em: <[http://www.bm.ust.hk/~acct/acsymp2012/papers/8-20-GNZ\\_2012.pdf](http://www.bm.ust.hk/~acct/acsymp2012/papers/8-20-GNZ_2012.pdf)>, acessado em 20 de outubro de 2016.

HAYKIN, Simon; *Neural Networks: A Comprehensive Foundation*. 2ª Ed. Pearson Education. 1999.

HU, Y.; FENG, B.; ZHANG, X.; NGAI, E. W. T.; LIU, M. *Stock trading rule Discovery with an evolutionary trend following model*. In: Expert Systems with Applications. Vol. 42, Issue 1. p. 212-222. 2015a.

HU, Y.; LIU, K.; ZHANG, X.; SU, L.; NGAI, E. W. T.; LIU, M. *Application of evolutionary computation for rule discovery in stock algorithmic trading: A literature review*. In: Applied Soft Computing. Vol. 36. p. 534-551. 2015b. Disponível em: <<https://www.researchgate.net/publication/282634620>>, acessado em 31 de outubro de 2016.

HUANG, G. B.; ZHU, Q. Y.; SIEW, C. K. *Extreme Learning Machine: A New Learning Scheme of Feedforward Neural Networks*. In: Proceedings of International Joint Conference on Neural Networks. Budapest, Hungary. 2004. Disponível em: <<https://www.researchgate.net/publication/4116697>>, acessado em 1º de novembro de 2016.

HUANG, G. B.; ZHU, Q. Y.; SIEW, C. K. *Extreme Learning Machine: Theory and applications*. In: Neurocomputing. Vol. 70. Issues 1-3. p. 489-501. . 2006. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S0925231206000385>>, acessado em 1º de novembro de 2016.

IBMEC, Instituto Brasileiro de Mercado de Capitais. *O Papel do Mercado de Capitais na economia brasileira*. 2016. Disponível em: <<http://ibmec.org.br/principal/o-papel-do-mercado-de-capitais-na-economia-brasileira/>>, acessado em 7 de agosto de 2016.

KAVAJECZ, K. A.; ODDERS-WHITE, E. R.; Technical Analysis and Liquidity Provision. In: Society for Financial Studies Conference on Investments in Imperfect Capital Markets. 2002. Disponível em <<http://moving-averages.technicalanalysis.org.uk/KaOd02.pdf>>, acessado em 25 de outubro de 2016.

KENNEDY, J.; EBERHART, R. *Particle Swarm Optimization*. In: IEEE International Conference on Neural Networks Proceedings. Vol 6. 1995. <<http://dx.doi.org/10.1109/ICNN.1995.488968>>, acessado em 31 de outubro de 2016.

KOZA, J. R. *Evolution of Subsumption Using Genetic Programming*. 1991. Disponível em: <<http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.3.9461&rep=rep1&type=pdf>>, acessado em 3 de novembro de 2016.

LOPES, J. A.; FIGUEIREDO, J. P.; BUOSI, M. G. *O Mercado de Capitais e a Abertura de Capital das Empresas*. Trabalho de Conclusão de Curso. UNIVEM. Marília, São Paulo. 2014. Disponível em <[http://aberto.univem.edu.br/bitstream/handle/11077/1156/O%20MERCADO%20DE%20CAPITAIS%20E%20A%20ABERTURA%20DE%20CAPITAL%20DAS%20EMPRESAS%20\(2\).pdf?sequence=1](http://aberto.univem.edu.br/bitstream/handle/11077/1156/O%20MERCADO%20DE%20CAPITAIS%20E%20A%20ABERTURA%20DE%20CAPITAL%20DAS%20EMPRESAS%20(2).pdf?sequence=1)>, acessado em 7 de outubro de 2016.

LUKE, S.; SPECTOR, L. *A Revised Comparison of Crossover and Mutation in Genetic Programming*. In: Genetic Programming 1998: Proceedings of the Third Annual Conference. p. 208-213. 1998. Disponível em: <<https://cs.gmu.edu/~sean/papers/revisedgp98.pdf>>, acessado em 3 de novembro de 2016.

MULLER, L. F.; FROZZA, R. *Processo de tomada de decisão usando Redes Neurais Artificiais e Agentes Inteligentes no domínio da predição do Mercado de Capitais*. Trabalho de conclusão de curso. UNISC. Santa Cruz do Sul. 2010.

NAMETALA, C. A. L.; PIMENTA, A.; PEREIRA, A. C. M.; CARRANO, E. G. *Uma estratégia automatizada de investimento por meio de redes neurais artificiais e preditores econômicos*. In: Simpósio Brasileiro de Sistemas de Informação 2016. 2016. Disponível em: <<https://www.researchgate.net/publication/303674805>>, acessado em 9 de Agosto de 2016.

NEELY, C. J.; WELLER, P. A. *Technical Analysis in the Foreign Exchange Market*. Research Division Federal Reserve Bank of St. Louis, Working Paper Series. St. Louis. 2011.

OSÓRIO, J. P. *A Análise Técnica e o Mercado Português: MACD e RSI*. Relatório de Projeto de Mestrado em Finanças. Instituto Superior de Ciências do Trabalho e da Empresa. Instituto Universitário de Lisboa. 2010. Disponível em <<https://repositorio.iscte-iul.pt/handle/10071/3593>>, acessado em 26 de outubro de 2016.

POLI, R.; KENNEDY, J.; BLACKWELL, T. *Particle swarm optimization: An overview*. In: Swarm Intelligence. Vol. 1. Issue 1. p. 33-57. 2007. Disponível em: <<https://dx.doi.org/10.1007/s11721-007-0002-0>>, acessado em 31 de outubro de 2016.

PARK, C.; IRWIN, S. H. *The profitability of Technical Analysis: A Review*. AgMAS Project Research Report 2004-04.

PORTAL DO INVESTIDOR. *O Papel da CVM*. Comissão de Valores Mobiliários. 2016. Disponível em < [http://www.portaldoinvestidor.gov.br/menu/primeiros\\_passos/papel\\_CVM.html](http://www.portaldoinvestidor.gov.br/menu/primeiros_passos/papel_CVM.html)>, acessado em 10 de outubro de 2016.

POTVIN, J. Y.; SORIANO, P.; VALLÉE, M. *Generating trading rules on the stock markets with genetic programming*. In: Computer & Operations Research. Vol. 31. p. 1033-1047. 2004. Disponível em: <<http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.108.834&rep=rep1&type=pdf>>, acessado em 3 de novembro de 2016.

RUSSEL, Stuart J.; NORVIG, Peter. *Artificial Intelligence: A Modern Approach*. 3<sup>rd</sup> Edition. Pearson, Upper Saddle River, 2010.

SUTTON, R. S.; BARTO, A. G. *Reinforcement Learning: An Introduction*. 2<sup>nd</sup> Edition. The MIT Press, Cambridge, Massachusetts. 2012.

TANG, J.; DENG, C.; HUANG, G. B. *Extreme Learning Machine for Multilayer Perceptron*. In: IEEE Transactions on Neural Networks and Learning Systems. Vol. 27. Issue 4. p. 809-821. 2016. Disponível em: <<http://dx.doi.org/10.1109/TNNLS.2015.2424995>>, acessado em 1º de novembro de 2016.

URQUHART, A.; BATTEN, J.; LUCEY, B.; MCGROARTY, F.; PEATE, M. *Does technical analysis beat the market? – Evidence from high frequency trading in gold and silver*. 2015. Disponível em: <[https://papers.ssrn.com/sol3/papers.cfm?abstract\\_id=2652637](https://papers.ssrn.com/sol3/papers.cfm?abstract_id=2652637)>, acessado em 19 de setembro de 2016.

VIDOTTO, R. S.; MIGLIATO, A. L. T.; ZAMBON, A. C. *O Moving Average Convergence-Divergence como ferramenta para a decisão de investimentos no mercado de ações*. Revista de Administração Contemporânea. Vol. 13. Nº 2. Curitiba. 2009. Disponível em <[http://www.scielo.br/scielo.php?script=sci\\_arttext&pid=S1415-65552009000200008](http://www.scielo.br/scielo.php?script=sci_arttext&pid=S1415-65552009000200008)>, acessado em 16 de outubro de 2016.

WANG, F.; YU, P. L. H.; CHEUNG, D. W. *Combining technical trading rules using particle swarm optimization*. In: Expert System with Applications. Vol. 41. Issue 6. p. 3016-3026. 2014.

WILDER, J. W. *New Concepts in Technical Trading Systems*. Trend Research. Greensboro. 1978.

WILSON, S. W. *ZCS: A Zeroth Level Classifier System*. In: Evolutionary Computation. Vol 2. Issue 1. p. 1-18. MIT Press. Cambridge. United States of America. 1994. Disponível em: <<https://www.eskimo.com/~wilson/ps/zcs.pdf>>, acessado em 2 de novembro de 2016.

WONG, W. K.; MANZUR, M.; CHEW, B. K. *How rewarding is technical analysis? Evidence from Singapore stock market*. In: Applied Finance Economics. Vol. 13. Issue 7. 2003. Disponível em <[http://repository.hkbu.edu.hk/cgi/viewcontent.cgi?article=1037&context=econ\\_ja](http://repository.hkbu.edu.hk/cgi/viewcontent.cgi?article=1037&context=econ_ja)>, acessado em 21 de outubro de 2016.